

Regresión lineal simple, polinomial y multivariable

Ruete, D. (2026). *Regresión lineal simple, polinomial, y multivariable* [Apunte]. Universidad Andrés Bello, Santiago, Chile.

Tabla de contenidos

Introducción	3
1. Introducción a los modelos de regresión.....	4
2. Fundamento matemático de la regresión	5
3. Regresión lineal simple	6
4. Métricas de error y calidad del ajuste.....	8
5. Regresión multivariable	9
6. Regresión polinomial.....	10
7. Supuestos del modelo de regresión	11
8. Sobreajuste y capacidad de generalización	12
9. Preparación de variables antes del entrenamiento	13
10. Interpretación de resultados del modelo.....	14
11. Caso aplicado integrado	15
12. Recursos pedagógicos de la unidad	16
12.1. Preguntas de autoevaluación	16
13. Glosario.....	17
Cierre.....	18
Referencias bibliográficas	19

Introducción

La regresión constituye una de las herramientas fundamentales del análisis estadístico y de la ciencia de datos, ya que permite modelar y predecir relaciones entre variables cuando la respuesta es de naturaleza continua. En este contexto, los modelos de regresión no solo cumplen un propósito predictivo, sino también explicativo, al facilitar la comprensión de cómo diferentes factores influyen en un fenómeno determinado. Desde aplicaciones en economía y finanzas hasta problemas en ingeniería, salud y marketing, la regresión se posiciona como un enfoque central para la toma de decisiones basada en datos.

Dentro de este marco, la regresión lineal simple representa el punto de partida conceptual, al establecer una relación directa entre una variable independiente y una variable dependiente mediante una función lineal. Sin embargo, los problemas reales suelen involucrar múltiples factores y comportamientos más complejos, lo que da lugar a extensiones como la regresión multivariable, que incorpora varios predictores simultáneamente, y la regresión polinomial, que permite capturar relaciones no lineales mediante transformaciones de las variables. Estas variantes amplían significativamente la capacidad de modelamiento, manteniendo al mismo tiempo una estructura matemática interpretable.

El estudio integrado de la regresión lineal simple, polinomial y multivariable permite desarrollar una comprensión progresiva del modelamiento predictivo, desde escenarios básicos hasta contextos más realistas y complejos. En esta unidad, se abordan no solo los fundamentos teóricos de estos modelos, sino también aspectos clave como la evaluación del desempeño, los supuestos estadísticos, la preparación de datos y la interpretación de resultados. De este modo, se busca que el estudiante no solo aplique técnicas de regresión, sino que también desarrolle un criterio analítico sólido para su uso adecuado en distintos contextos profesionales.


1. Introducción a los modelos de regresión

En el aprendizaje supervisado, los modelos de regresión se utilizan cuando la variable objetivo es continua, es decir, cuando el resultado que se desea predecir puede tomar una amplia gama de valores numéricos. Este tipo de problemas aparece en contextos muy diversos: predicción del precio de una vivienda, estimación de demanda energética, proyección de ventas, cálculo de tiempo de espera o modelamiento de variables biomédicas como presión arterial, glicemia o nivel de colesterol.

La regresión no solo cumple una función predictiva. También permite interpretar relaciones entre variables y construir explicaciones cuantitativas del fenómeno estudiado. Por esta razón, ocupa un lugar central tanto en estadística clásica como en ciencia de datos moderna. Este capítulo desarrolla, en coherencia con el indicador ID2.1, los fundamentos de la regresión lineal simple, la regresión polinomial y la regresión multivariable, integrando además el análisis de coeficientes, supuestos, métricas de evaluación y preparación de variables.

Desde una perspectiva general, la regresión busca aproximar una relación funcional entre un conjunto de entradas y una salida continua. Este principio puede expresarse como $Y = f(X) + \varepsilon$, donde Y representa la variable dependiente, X representa una o más variables independientes y ε corresponde al componente de error aleatorio. El objetivo del modelamiento consiste en construir una estimación útil de la función f , de modo que el sistema pueda predecir valores razonables para observaciones nuevas.

Imagen 1. Relación lineal entre una variable explicativa y una variable objetivo, junto con la recta de regresión ajustada



Fuente: elaboración propia.

La imagen 1 ilustra la intuición básica del problema. Cada punto representa una observación y la recta sintetiza la tendencia promedio entre la variable de entrada y la variable de salida. Si el comportamiento observado es aproximadamente lineal, la regresión lineal simple puede ofrecer un modelo parsimonioso, interpretable y suficientemente preciso para la tarea.

2. Fundamento matemático de la regresión

La función de regresión es la relación sistemática que vincula las variables de entrada con la variable objetivo. En términos formales, el modelo general se representa mediante la expresión $Y = f(X) + \varepsilon$. El término $f(X)$ representa la parte estructurada del fenómeno, mientras que ε recoge la variación no explicada por el modelo. Esta variación puede deberse a factores no medidos, ruido de medición, aleatoriedad inherente al proceso o especificación imperfecta del modelo.

La idea de aproximación es esencial. En aplicaciones reales, rara vez se conoce la verdadera función generadora de los datos. Por lo tanto, el analista construye una función estimada, denotada como $\hat{y} = f(X)$, cuyo propósito es acercarse lo más posible al comportamiento observado. La calidad de esa aproximación se evalúa mediante métricas de error.

La variable dependiente, también denominada variable objetivo, respuesta o salida, es la magnitud que se desea predecir. Las variables independientes, predictoras o explicativas son aquellas que contienen información potencialmente útil para explicar la variación en la respuesta.



En un problema de predicción de precios inmobiliarios, por ejemplo, el precio es la variable dependiente y la superficie, la ubicación, el número de habitaciones y la antigüedad pueden funcionar como variables independientes.

El error de predicción es la diferencia entre el valor real observado y el valor estimado por el modelo. Para una observación i , este error se expresa como $ei = yi - \hat{y}i$. Si el error es positivo, el modelo subestimó el valor real; si es negativo, el modelo sobrestimó el resultado. El estudio sistemático de estos errores es fundamental para evaluar la calidad del ajuste y para verificar supuestos del modelo.

3. Regresión lineal simple

La regresión lineal simple es el modelo más elemental de regresión. Se utiliza cuando se desea explicar o predecir una variable continua a partir de una única variable independiente. Su ecuación general es $Y = \beta_0 + \beta_1 X + \varepsilon$. En esta expresión, β_0 es el intercepto o término independiente, β_1 es la pendiente y ε es el error aleatorio.

El intercepto β_0 representa el valor esperado de Y cuando la variable independiente X toma el valor cero. Aunque no siempre tiene una interpretación sustantiva directa, es un componente esencial del modelo porque define el punto en que la recta de regresión corta el eje vertical.

La pendiente β_1 cuantifica el cambio esperado en la variable dependiente ante un aumento unitario en la variable independiente. Si β_1 es positiva, la relación es directa: al aumentar X , también aumenta Y . Si β_1 es negativa, la relación es inversa: al aumentar X , disminuye Y . La pendiente constituye uno de los parámetros más importantes de interpretar en regresión, lo que se vincula directamente con el indicador ID2.2.


Por ejemplo, si se obtiene el modelo $\text{Precio} = 50.000 + 1.200 \cdot \text{Superficie}$, la interpretación de β_1 indica que, en promedio, cada metro cuadrado adicional se asocia con un aumento de 1.200 unidades monetarias en el precio, manteniendo el resto de las condiciones constantes. En el caso de la regresión lineal simple, no hay otras variables adicionales que controlar, por lo que la interpretación se centra exclusivamente en la relación entre X e Y .

El procedimiento más habitual para estimar los coeficientes de la recta de regresión es el método de mínimos cuadrados ordinarios. Su idea central es seleccionar los valores de β_0 y β_1 que minimizan la suma de los errores al cuadrado. La función objetivo se escribe como $\sum (y_i - \hat{y}_i)^2$. Elevar al cuadrado cada error evita que errores positivos y negativos se cancelen entre sí y, además, penaliza con mayor fuerza las desviaciones grandes.

Desde una perspectiva geométrica, el método de mínimos cuadrados busca la recta que deja, en promedio, las menores distancias verticales cuadráticas respecto de los puntos observados. Desde una perspectiva algebraica, resuelve un problema de optimización cuyo resultado entrega estimadores únicos bajo ciertas condiciones.

Considera una base de datos de viviendas en la que se registra la superficie y el precio de venta. Si los datos muestran una relación aproximadamente lineal, puede ajustarse una regresión lineal simple para estimar el precio a partir de la superficie. Este modelo es útil tanto para predecir el valor de una vivienda nueva como para explicar cuantitativamente el efecto marginal de la superficie sobre el precio.

Imagen 2. Distribución residual bajo homocedasticidad y heterocedasticidad. La estabilidad de la dispersión es un supuesto importante del modelo



Fuente: elaboración propia.

4. Métricas de error y calidad del ajuste

El error cuadrático medio, o *Mean Squared Error*, es una de las métricas más utilizadas en regresión. Se define como el promedio de los errores al cuadrado y se expresa mediante la fórmula $MSE = (1/n) \cdot \sum (y_i - \hat{y}_i)^2$. Conceptualmente, mide cuánto se alejan, en promedio, las predicciones del modelo respecto de los valores observados.

El MSE tiene dos características importantes. En primer lugar, siempre toma valores no negativos. En segundo lugar, es particularmente sensible a errores grandes, ya que estos se amplifican al elevarse al cuadrado. Esta propiedad puede ser deseable cuando se desea penalizar con fuerza predicciones muy erróneas.

La raíz del error cuadrático medio, RMSE, corresponde a la raíz cuadrada del MSE. Su principal ventaja es que expresa el error en las mismas unidades de la variable objetivo. Si se predice precio, el RMSE también estará en unidades monetarias; si se predice tiempo, estará en unidades de tiempo. Por ello suele ser más intuitivo para la interpretación aplicada.

El coeficiente de determinación, R^2 , cuantifica la proporción de la variabilidad total de la variable dependiente que es explicada por el modelo. Se calcula como $R^2 = 1 - (SS_{\text{res}} / SS_{\text{tot}})$, donde SS_{res} representa la suma de cuadrados de los residuos y SS_{tot} representa la suma de cuadrados total. Un valor cercano a 1 indica que el modelo explica gran parte de la variabilidad observada; un valor cercano a 0 indica capacidad explicativa reducida.

Es importante subrayar que un R^2 alto no garantiza por sí mismo que el modelo sea correcto o útil fuera de la muestra. Un modelo sobreajustado también puede exhibir un R^2 elevado en entrenamiento. Por ello, la interpretación del R^2 debe complementarse con el análisis de residuos, validación y criterio sustantivo.


En docencia y práctica profesional, es recomendable no depender de una sola métrica. MSE y RMSE reflejan error absoluto de predicción, mientras que R^2 refleja capacidad explicativa relativa. Evaluar simultáneamente estas medidas permite una visión más equilibrada del desempeño del modelo.

5. Regresión multivariable

La regresión multivariable, también denominada regresión lineal múltiple, amplía el modelo lineal simple incorporando múltiples variables explicativas. Su forma general es $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p + \varepsilon$. Esta extensión es particularmente relevante en ciencia de datos, donde los problemas reales rara vez dependen de una sola variable.

La fortaleza principal de este enfoque es que permite modelar el efecto conjunto de varios predictores. Además, cada coeficiente puede interpretarse como el efecto parcial de una variable, manteniendo constantes las demás. Esta propiedad es crucial cuando se desea controlar factores de confusión o construir explicaciones más realistas del fenómeno.

Imagen 3. Representación de una superficie de regresión multivariable para dos variables explicativas



Fuente: elaboración propia.

Supón el modelo $\text{Precio} = 40.000 + 900 \cdot \text{Superficie} + 5.000 \cdot \text{Ubicación} + 2.000 \cdot \text{Habitaciones}$. En este caso, el coeficiente de superficie indica el cambio esperado en el precio por cada metro cuadrado adicional, manteniendo constantes ubicación y número de habitaciones. El coeficiente de ubicación, si ha sido codificado apropiadamente, expresa la diferencia promedio asociada a la localización de la vivienda, controlando el resto de los factores incluidos.


Uno de los desafíos en regresión multivariable es la colinealidad o multicolinealidad. Este fenómeno ocurre cuando dos o más variables independientes están fuertemente correlacionadas entre sí. Como consecuencia, se vuelve difícil estimar de forma estable el efecto individual de cada predictor. La colinealidad puede aumentar la varianza de los coeficientes, dificultar la interpretación y volver inestable el modelo.

En una institución de salud, la estimación del tiempo de hospitalización puede depender simultáneamente de edad, severidad clínica, presencia de comorbilidades y resultado de exámenes de laboratorio. Un modelo multivariable permite capturar esta combinación de efectos y realizar una predicción más útil que la obtenida con una sola variable.

6. Regresión polinomial

La regresión polinomial se emplea cuando la relación entre una variable explicativa y la respuesta no es lineal, pero puede aproximarse mediante una función curva. Su estructura general incorpora potencias de la variable X , por ejemplo, $Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \varepsilon$. Es importante enfatizar que, aunque el comportamiento respecto de X es no lineal, el modelo sigue siendo lineal en los parámetros β , lo que facilita su estimación.

Imagen 4. Ajuste polinomial para una relación no lineal entre X y Y



Fuente: elaboración propia.

La regresión polinomial es útil cuando los datos muestran curvatura sistemática. En economía, por ejemplo, ciertos rendimientos pueden crecer y luego decrecer; en salud, el efecto de una dosis puede no aumentar de manera proporcional; en ingeniería, muchas relaciones físicas presentan comportamiento parabólico o cúbico. En estos casos, imponer una relación estrictamente lineal puede subestimar la estructura real de los datos.

A medida que aumenta el grado del polinomio, el modelo gana flexibilidad. Sin embargo, esta flexibilidad adicional puede conducir a sobreajuste. Un polinomio de grado demasiado alto puede seguir con precisión los puntos de entrenamiento y, al mismo tiempo, perder capacidad de generalización. Por esta razón, la elección del grado debe basarse en evidencia empírica y no solo en capacidad de ajuste dentro de la muestra.

7. Supuestos del modelo de regresión

El supuesto de linealidad establece que la relación media entre la variable dependiente y los predictores puede describirse mediante una combinación lineal de los parámetros. Esto no significa necesariamente que todas las variables deban relacionarse en forma recta con la respuesta, ya que pueden incorporarse transformaciones o términos polinomiales; significa, más bien, que el modelo debe estar correctamente especificado en su forma funcional.

La independencia implica que los errores asociados a distintas observaciones no estén correlacionados entre sí. Este supuesto es especialmente relevante en series temporales o datos secuenciales, donde errores consecutivos pueden presentar autocorrelación. Cuando la independencia falla, las inferencias estadísticas sobre coeficientes pueden resultar engañosas.

La homocedasticidad establece que la varianza del error sea aproximadamente constante para todos los niveles de la predicción. Cuando este supuesto no se cumple, se habla de heterocedasticidad. La heterocedasticidad puede no afectar gravemente la capacidad predictiva puntual, pero sí comprometer la precisión de intervalos y pruebas de significación.


La normalidad de los errores es un supuesto que favorece la validez de ciertos procedimientos inferenciales, como pruebas de hipótesis e intervalos de confianza. En problemas con muestras grandes, pequeñas desviaciones de la normalidad suelen ser menos preocupantes. En muestras pequeñas, en cambio, este supuesto merece mayor atención.

En docencia aplicada, la revisión de supuestos suele apoyarse en gráficos de residuos, histogramas, gráficos Q-Q y análisis de patrones sistemáticos. La verificación no debe entenderse como un requisito puramente ritual, sino como un componente esencial para evaluar si el modelo está representando de manera razonable el fenómeno estudiado.

8. Sobreajuste y capacidad de generalización

El sobreajuste, u *overfitting*, ocurre cuando el modelo se ajusta en exceso a los datos de entrenamiento y aprende no solo la señal relevante, sino también el ruido particular de la muestra. En consecuencia, el desempeño dentro del conjunto de entrenamiento puede parecer excelente, pero el error aumenta cuando el modelo enfrenta datos nuevos.

Imagen 5. Comparación entre un ajuste razonable y un modelo sobreajustado



Fuente: elaboración propia.

La generalización es la capacidad del modelo para mantener un desempeño adecuado en observaciones no vistas durante el entrenamiento. En ciencia de datos, generalizar correctamente es más importante que memorizar el conjunto de entrenamiento. Por ello, el diseño de modelos debe buscar un equilibrio entre flexibilidad y robustez.

En regresión polinomial, por ejemplo, un grado alto puede reducir fuertemente el error en entrenamiento. Sin embargo, ese mismo modelo puede oscilar de manera artificial entre observaciones y producir predicciones inestables. Este fenómeno justifica la necesidad de validación cruzada, partición de datos y selección cuidadosa de complejidad.

9. Preparación de variables antes del entrenamiento

El escalamiento consiste en transformar las variables para que operen en escalas comparables. Aunque la regresión lineal clásica no siempre exige escalamiento para funcionar, esta práctica facilita la interpretación comparativa, mejora la estabilidad numérica y resulta especialmente importante cuando se combinan técnicas de regularización o se comparan coeficientes estandarizados.

La normalización transforma una variable para llevarla a un rango acotado, típicamente entre 0 y 1. La fórmula común es $X' = (X - X_{\min}) / (X_{\max} - X_{\min})$. Esta estrategia es útil cuando se desea preservar proporciones relativas dentro de un rango fijo.

La estandarización transforma una variable restando su media y dividiendo por su desviación estándar, es decir, $X' = (X - \mu) / \sigma$. El resultado es una variable con media cero y desviación estándar uno. Esta transformación permite comparar efectos en una misma escala y ayuda a detectar valores extremos relativos.

Las variables categóricas no pueden introducirse directamente en un modelo de regresión lineal sin ser codificadas. Una estrategia común es la codificación *dummy* u *one-hot encoding*, donde cada categoría se representa mediante variables binarias. La interpretación de los coeficientes codificados debe hacerse siempre respecto de una categoría de referencia.

La selección de variables busca conservar predictores relevantes y reducir aquellos redundantes o irrelevantes. Esta etapa mejora la interpretabilidad, reduce riesgo de colinealidad y puede favorecer la generalización. Sin embargo, la eliminación de variables no debe basarse solo en automatismos, sino también en criterio sustantivo y conocimiento del problema.

10. Interpretación de resultados del modelo

Interpretar un modelo de regresión significa traducir parámetros y métricas a conclusiones comprensibles y útiles para la toma de decisiones. Esta tarea exige distinguir cuidadosamente entre asociación estadística y causalidad. Un coeficiente significativo no demuestra por sí solo que una variable cause cambios en la respuesta; indica, en términos generales, que existe una relación consistente dentro de los datos observados.

El signo del coeficiente expresa la dirección de la relación. Un coeficiente positivo indica asociación directa; un coeficiente negativo indica asociación inversa. Esta lectura debe situarse siempre en el contexto del fenómeno analizado y del resto de variables incluidas en el modelo.

La magnitud del coeficiente expresa cuánto cambia la variable dependiente ante una variación unitaria de la independiente. Sin embargo, esta interpretación depende de la escala original de la variable. Por ello, variables medidas en unidades muy distintas pueden dar lugar a coeficientes difícilmente comparables si no han sido estandarizadas.

Si un modelo para estimar ventas semanales entrega la ecuación $\text{Ventas} = 2.000 + 150 \cdot \text{PublicidadDigital} - 80 \cdot \text{TiempoDeEntrega}$, la interpretación sería la siguiente: manteniendo constantes las demás variables del modelo, una unidad adicional de inversión en publicidad digital se asocia con un aumento promedio de 150 unidades en ventas, mientras que un aumento unitario del tiempo de entrega se asocia con una disminución promedio de 80 unidades en ventas.

La lectura de resultados debe combinar coeficientes, métricas de error, revisión de residuos y pertinencia contextual. Un modelo puede ofrecer métricas aceptables y, aun así, ser poco útil si la especificación de variables no responde al problema real que se intenta resolver.

11. Caso aplicado integrado

Considérese un problema de predicción del precio de viviendas. El conjunto de datos contiene superficie construida, antigüedad, cantidad de habitaciones, ubicación y precio final de venta. El objetivo es entrenar un modelo que permita estimar el precio de nuevas propiedades sobre la base de estas variables.

En una primera fase, podría entrenarse una regresión lineal simple usando solo la superficie como predictor. Este modelo permite una interpretación clara del efecto marginal de los metros cuadrados, pero probablemente omite factores relevantes. En una segunda fase, podría construirse una regresión multivariable incorporando ubicación, habitaciones y antigüedad. Este nuevo modelo ofrecería una representación más completa del fenómeno.

Si se detecta que la relación entre antigüedad y precio no es lineal, puede incorporarse un término cuadrático para capturar curvatura. En ese punto, el modelo combina componentes lineales y polinomiales, lo que permite un ajuste más realista sin abandonar la interpretabilidad. Finalmente, su evaluación se realizaría mediante MSE, RMSE y R^2 , complementando el análisis con revisión de residuos y validación fuera de muestra.

Este caso muestra cómo los tres indicadores de desempeño de la unidad se integran en un mismo flujo de trabajo: se implementan modelos de regresión, se interpretan coeficientes y se evalúa el desempeño mediante métricas adecuadas.

12. Recursos pedagógicos de la unidad

- ¿En qué situaciones conviene privilegiar un modelo lineal simple por sobre uno más complejo?
- ¿Qué riesgos aparecen al interpretar un coeficiente sin considerar la escala de la variable?
- ¿Cómo afecta la colinealidad a la lectura de resultados en regresión multivariable?
- ¿Por qué un modelo con bajo error de entrenamiento puede desempeñarse mal en datos nuevos?

12.1. Preguntas de autoevaluación

- Define regresión lineal simple y explica el significado de sus parámetros.
- ¿Qué es el error cuadrático medio y por qué penaliza con fuerza los errores grandes?
- Explica la diferencia entre regresión lineal múltiple y regresión polinomial.
- ¿Qué se entiende por homocedasticidad en un modelo de regresión?
- Define sobreajuste y describa una estrategia para mitigarlo.
- ¿Qué expresa el coeficiente de determinación R^2 ?

13. Glosario

Tabla 1. Glosario de conceptos fundamentales

Concepto	Definición
Colinealidad	Alta correlación entre variables explicativas, que dificulta la estimación e interpretación de coeficientes.
Homocedasticidad	Supuesto según el cual la varianza de los errores permanece aproximadamente constante.
Intercepto	Valor esperado de la variable dependiente cuando todas las variables independientes toman el valor cero.
MSE	Promedio de los errores al cuadrado entre valores reales y predichos.
Pendiente	Cambio esperado en la respuesta ante una variación unitaria en una variable explicativa.
Regresión	Técnica de modelamiento utilizada para predecir o explicar una variable continua a partir de una o más variables independientes.
RMSE	Raíz cuadrada del MSE; expresa el error en las mismas unidades de la variable objetivo.
R^2	Proporción de la variabilidad de la respuesta explicada por el modelo.
Residuo	Diferencia entre el valor observado y el valor predicho por el modelo.
Sobreajuste	Ajuste excesivo del modelo a la muestra de entrenamiento, que deteriora la generalización.

Fuente: elaboración propia.

Cierre

En esta unidad se desarrollaron de manera integral los fundamentos teóricos y aplicados de los modelos de regresión orientados a la predicción de variables continuas. Se examinó la regresión lineal simple como punto de partida para comprender la relación entre variables, así como su ampliación hacia modelos multivariados, que permiten capturar la influencia conjunta de múltiples factores. Además, se incorporó la regresión polinomial como una alternativa para modelar relaciones no lineales, ampliando la capacidad de representación de los modelos sin perder interpretabilidad.

Asimismo, se profundizó en la interpretación de los coeficientes como elementos clave para la toma de decisiones, junto con el uso de métricas de evaluación como el MSE, RMSE y R^2 , que permiten valorar la calidad del ajuste y el desempeño predictivo. De igual manera, se destacaron los supuestos fundamentales del modelo de regresión y su relevancia para garantizar resultados válidos, así como los riesgos asociados al sobreajuste y la importancia de la capacidad de generalización.



En conjunto, los contenidos abordados permiten al estudiante no solo comprender la lógica del modelamiento mediante regresión, sino también aplicarlo de manera crítica y fundamentada en contextos reales. Esto implica no solo construir modelos, sino evaluarlos, interpretarlos y ajustarlos considerando tanto criterios estadísticos como el contexto del problema, fortaleciendo así competencias analíticas clave en el ámbito de la ciencia de datos y la toma de decisiones.

Referencias bibliográficas

Alpaydin, E. (2010). *Introduction to machine learning*. MIT Press.

Géron, A. (2019). *Hands-on machine learning with Scikit-Learn, Keras and TensorFlow*. O'Reilly Media.

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An introduction to statistical learning: with applications in R* (2nd ed.). Springer.

Provost, F., & Fawcett, T. (2013). *Data science for business*. O'Reilly Media.