

Regresión con árboles de decisión

Ruete, D. (2026). *Regresión con árboles de decisión* [Apunte].
Universidad Andrés Bello, Santiago, Chile.

Tabla de contenidos

Introducción	4
1. Fundamento conceptual del árbol de regresión.....	5
1.1. Definición.....	5
1.2. Representación matemática	5
2. ¿Cómo particiona el espacio un árbol de decisión?	6
2.1. Partición recursiva binaria	6
2.2. Criterio de homogeneidad.....	6
2.3. Predicción por hojas.....	6
3. Criterios de división	7
3.1. Suma de cuadrados residual	7
3.2. Interpretación pedagógica del criterio.....	7
3.3. División local versus estructura global	7
4. Profundidad del árbol y complejidad del modelo	8
4.1. Definición de profundidad	8
4.2. Árboles poco profundos	8
4.3. Árboles muy profundos.....	8
5. Sobreajuste en árboles de regresión	9
5.1. Definición	9
5.2. Síntomas del sobreajuste.....	9
5.3. Impacto pedagógico y analítico	9
6. Poda del modelo	10
6.1. ¿Qué es la poda?.....	10
6.2. Poda por complejidad de costo.....	10
6.3. Selección del mejor nivel de poda.....	10
6.4. Pre-poda y post-poda	11
7. Ventajas y limitaciones del enfoque	12
7.1. Ventajas.....	12
7.2. Limitaciones	12
7.3. ¿Cuándo conviene usarlos?.....	12
8. Árboles versus regresión lineal	13
9. Aplicaciones en problemas de predicción.....	14
10. Caso aplicado integrado.....	15

11. Recursos pedagógicos de la unidad	16
11.1. Preguntas de reflexión.....	16
11.2. Preguntas de autoevaluación	16
11.3. Glosario de conceptos fundamentales	16
Cierre.....	18
Referencias bibliográficas	19


Introducción

Los árboles de decisión para regresión constituyen un enfoque no paramétrico dentro del aprendizaje supervisado. Su objetivo es predecir variables continuas a partir de un conjunto de predictores, pero lo hacen de una manera distinta a la regresión lineal o polinomial: en lugar de ajustar una única ecuación global sobre todo el conjunto de datos, dividen el espacio de variables en regiones sucesivas y asignan a cada región una predicción constante.

Esta forma de modelar resulta especialmente útil cuando la relación entre variables es compleja, no lineal o cuando existen interacciones difíciles de expresar con una sola fórmula. En el programa de la asignatura, este contenido se ubica en la Unidad 2: Modelos de aprendizaje Supervisado – Regresión, dentro del apartado Regresión con Árboles de Decisión, junto a otros modelos para variables continuas como regresión lineal, Random Forest, SVR y redes neuronales.

Desde una perspectiva pedagógica, los árboles de decisión son valiosos porque permiten visualizar el proceso de modelamiento como una secuencia de preguntas o reglas. En lugar de pensar el modelo como una ecuación abstracta, es posible interpretarlo como una estructura jerárquica de nodos y ramas que conducen a una predicción final. Esto facilita el aprendizaje del indicador ID2.2, vinculado a la interpretación de particiones, reglas y hojas terminales.

Imagen 1. Partición del espacio de variables y predicción por hojas en un árbol de regresión



Fuente: elaboración propia.

1. Fundamento conceptual del árbol de regresión

1.1. Definición

Un árbol de regresión es un modelo que aproxima una función de predicción mediante un conjunto de regiones disjuntas del espacio de entrada. Cada una de estas regiones, también llamadas nodos terminales u hojas, contiene observaciones similares según ciertos criterios de división, y a cada hoja se le asigna un valor de predicción, usualmente el promedio de la variable objetivo dentro de esa región.


En términos intuitivos, el árbol va formulando particiones del tipo “si X_j es menor o igual que un umbral c , entonces continuar por la izquierda; en caso contrario, continuar por la derecha”. Al repetirse este procedimiento de manera recursiva, se genera una estructura jerárquica que segmenta el espacio de variables en subregiones más homogéneas.

1.2. Representación matemática

A diferencia de la regresión lineal, que asume una forma global de la función del tipo $f(X) = \beta_0 + \sum \beta_j X_j$, un árbol de regresión asume una representación por regiones. En el texto de James, Witten, Hastie y Tibshirani, los árboles se representan como una partición del espacio de características $R_1, \dots, R_M$, donde la predicción en cada región es una constante c_m . Conceptualmente, esto significa que el modelo adopta una función por tramos, más cercana a una superficie escalonada que a una recta o plano continuo.

Esta propiedad explica por qué los árboles son capaces de capturar relaciones no lineales y patrones con umbrales, pero también por qué pueden presentar superficies de predicción abruptas. En problemas donde la variable objetivo cambia por segmentos o depende de rangos críticos, esta forma de modelar puede ser muy útil.

Imagen 2. Ejemplo de estructura jerárquica de un árbol de regresión con tres hojas terminales



Fuente: elaboración propia.

2. ¿Cómo particiona el espacio un árbol de decisión?

2.1. Partición recursiva binaria

El mecanismo central de construcción de un árbol de regresión es la partición recursiva binaria. "Binaria" significa que en cada paso se divide un nodo en exactamente dos subnodos. "Recursiva" significa que ese procedimiento se repite una y otra vez sobre los nodos resultantes, siempre que la división mejore el ajuste y no viole los criterios de detención establecidos.

El árbol explora combinaciones del tipo $X_j \leq c$, donde X_j es una de las variables predictoras y c es un punto de corte candidato. Para cada regla posible, se evalúa qué tan homogéneos quedan los subgrupos resultantes respecto de la variable objetivo. La regla seleccionada es la que reduce con mayor eficacia la variabilidad interna en los nodos hijos.

2.2. Criterio de homogeneidad

En regresión, el criterio más habitual para medir homogeneidad es el error cuadrático medio dentro del nodo, o de manera equivalente, la suma de cuadrados residual local. Un nodo es más homogéneo cuando las observaciones que contiene tienen valores de respuesta más parecidos entre sí. Por ello, las divisiones "buenas" son aquellas que producen grupos con menor dispersión interna.

Si un nodo contiene respuestas muy heterogéneas, una sola predicción constante para todo ese nodo será poco representativa. En cambio, si una división logra separar observaciones altas de observaciones bajas, la predicción promedio dentro de cada hoja resultará más precisa. Este principio conecta directamente con el indicador ID2.3, ya que la lógica del árbol está gobernada por la minimización del error.

2.3. Predicción por hojas

Una vez construidas las particiones, la predicción de una nueva observación consiste en seguir las reglas del árbol hasta llegar a una hoja terminal. La predicción asignada será el valor representativo de esa hoja, normalmente la media de la variable objetivo entre las observaciones de entrenamiento que quedaron en ella.

Esta forma de predicción implica que el árbol produce valores constantes por regiones. Por ello, dos observaciones cercanas que caigan dentro de la misma hoja recibirán la misma predicción, mientras que observaciones apenas separadas por un umbral de corte pueden obtener valores predichos distintos. Esta es una de las características más distintivas de los árboles de regresión.

3. Criterios de división

3.1. Suma de cuadrados residual

En árboles de regresión, el criterio estándar de división consiste en minimizar la suma de cuadrados residual dentro de las regiones generadas. Si un nodo se divide en dos regiones, izquierda y derecha, el algoritmo calcula la suma de los errores al cuadrado al reemplazar cada respuesta por la media de su región. La mejor división será aquella que reduzca al máximo esa suma.

Formalmente, para una región R , la predicción del nodo es el promedio de las respuestas en R . El error asociado a esa región se calcula como la suma de $(y_i - \hat{y}_R)^2$ para todas las observaciones del nodo. La división óptima es la que minimiza la suma de errores de las dos regiones hijas. Esta lógica es coherente con el uso del MSE como métrica general de evaluación en modelos de regresión dentro de la Unidad 2.

3.2. Interpretación pedagógica del criterio

Desde un punto de vista pedagógico, puede decirse que el árbol busca “preguntas” que produzcan grupos más puros respecto del valor continuo que se desea predecir. Si una variable logra separar muy bien observaciones de precio alto y precio bajo, entonces esa variable será una buena candidata para una división temprana. Si, en cambio, una variable apenas reduce la dispersión, el árbol tenderá a descartarla en las primeras etapas.

3.3. División local versus estructura global

Una limitación importante es que el árbol toma decisiones localmente. Cada división se elige por el beneficio inmediato que produce en el nodo actual. Esta característica explica por qué árboles distintos pueden emerger ante pequeñas variaciones en los datos y también por qué el modelo puede requerir procedimientos posteriores de simplificación, como la poda.

4. Profundidad del árbol y complejidad del modelo

4.1. Definición de profundidad

La profundidad de un árbol corresponde al número de niveles o pasos que una observación debe recorrer desde la raíz hasta una hoja terminal. Un árbol más profundo contiene más divisiones, más nodos internos y, en general, más hojas. En términos prácticos, la profundidad funciona como un parámetro de complejidad del modelo.


4.2. Árboles poco profundos

Un árbol demasiado pequeño puede incurrir en subajuste. Esto ocurre cuando las particiones son insuficientes para representar la estructura real de los datos. En ese escenario, la predicción tiende a ser demasiado grosera, porque un mismo valor promedio se aplica a regiones muy amplias del espacio de entrada.

4.3. Árboles muy profundos

Un árbol excesivamente profundo, por el contrario, puede ajustar con mucha precisión el conjunto de entrenamiento, pero capturar ruido y particularidades accidentales de la muestra. En este caso aparece el sobreajuste. El error de entrenamiento disminuye, pero la capacidad de generalización se deteriora.

Imagen 3. Contraste entre un árbol poco profundo y un árbol muy profundo



Fuente: elaboración propia.

El equilibrio entre profundidad y generalización es uno de los aspectos centrales en la enseñanza y uso de árboles de regresión. Por ello, la complejidad del árbol debe controlarse mediante reglas de parada, criterios de tamaño mínimo de nodo o técnicas de poda.

5. Sobreajuste en árboles de regresión

5.1. Definición

El sobreajuste ocurre cuando el árbol se adapta demasiado al conjunto de entrenamiento y termina modelando ruido o fluctuaciones aleatorias, en lugar de capturar únicamente la señal útil. En árboles de decisión, este problema es frecuente porque el algoritmo puede seguir dividiendo nodos hasta producir hojas muy pequeñas con muy pocas observaciones.

5.2. Síntomas del sobreajuste

Los síntomas clásicos son un error de entrenamiento muy bajo y un error de validación o prueba significativamente mayor. El árbol parece "excelente" en la muestra observada, pero su desempeño fuera de la muestra es débil. Desde una perspectiva visual, el sobreajuste suele reflejarse en una estructura demasiado fragmentada, con ramas largas, muchas hojas y reglas excesivamente específicas.

5.3. Impacto pedagógico y analítico

En docencia, este concepto es relevante porque permite mostrar de forma tangible el compromiso entre flexibilidad e interpretación. Un árbol muy simple puede resultar demasiado rígido; uno muy grande puede perder valor explicativo y predictivo. Por tanto, el aprendizaje del modelo no termina en la construcción del árbol, sino que exige evaluar críticamente su tamaño y su estabilidad.

6. Poda del modelo

6.1. ¿Qué es la poda?

La poda es el proceso de simplificar un árbol previamente crecido, eliminando ramas que aportan poco valor predictivo. Su objetivo es reducir la complejidad del modelo, controlar la varianza y mejorar la generalización. En lugar de detener el crecimiento demasiado temprano, una estrategia recomendada consiste en hacer crecer un árbol relativamente grande y luego recortarlo.


6.2. Poda por complejidad de costo

El texto base de James y colaboradores propone la poda por complejidad de costo, también llamada *weakest link pruning*. La idea es seleccionar subárboles mediante un parámetro α que penaliza la complejidad del árbol. A mayor α , mayor costo por mantener muchas hojas y, por tanto, mayor presión hacia árboles más pequeños. Este proceso se expresa como una optimización que combina ajuste a los datos y número de nodos terminales.

6.3. Selección del mejor nivel de poda

Una vez generada una secuencia de subárboles, el valor óptimo de α puede seleccionarse usando validación cruzada. El procedimiento general descrito por James et al. (2021) consiste en crecer un árbol grande, aplicar poda por complejidad de costo para obtener varios subárboles y luego usar *K-fold cross-validation* para elegir el que minimiza el error promedio de validación.

Imagen 4. Contraste entre un árbol poco profundo y un árbol muy profundo



Fuente: elaboración propia.

6.4. Pre-poda y post-poda

En la práctica se distinguen dos enfoques. La pre-poda restringe el crecimiento desde el inicio, por ejemplo, imponiendo profundidad máxima, número mínimo de observaciones por hoja o reducción mínima del error para autorizar una división. La post-poda, en cambio, permite crecer el árbol y luego eliminar ramas. Pedagógicamente, la post-poda suele ser más ilustrativa porque permite comparar el árbol completo con su versión simplificada.

7. Ventajas y limitaciones del enfoque

7.1. Ventajas

Los árboles de decisión tienen varias ventajas destacadas. Son fáciles de explicar, pueden representarse gráficamente y suelen resultar intuitivos incluso para usuarios no expertos. Además, manejan de forma natural relaciones no lineales, interacciones complejas y predictores cualitativos sin necesidad de una especificación algebraica compleja. Estas características los convierten en una herramienta muy atractiva en contextos de comunicación y toma de decisiones.

El texto de referencia subraya precisamente que los árboles son muy fáciles de explicar, que algunas personas consideran que reflejan mejor la toma de decisiones humana, que pueden mostrarse gráficamente y que manejan predictores cualitativos sin necesidad de crear variables *dummy*.

7.2. Limitaciones

Sin embargo, los árboles también presentan limitaciones. Su precisión predictiva, tomada de forma aislada, puede ser menor que la de otros modelos más avanzados. Además, son inestables: pequeños cambios en los datos pueden dar lugar a árboles diferentes. Esta falta de robustez se relaciona con su alta varianza. Por ello, aunque son muy interpretables, no siempre son la opción óptima cuando el criterio principal es maximizar desempeño predictivo.

El mismo texto de James y colaboradores señala que, en términos generales, los árboles no suelen alcanzar el mismo nivel de precisión predictiva que otros métodos de regresión y clasificación, y que además pueden ser muy no robustos frente a pequeñas perturbaciones de los datos.

7.3. ¿Cuándo conviene usarlos?

Los árboles de regresión son especialmente útiles cuando la interpretabilidad es una prioridad, cuando se sospechan relaciones no lineales, cuando existen umbrales relevantes en las variables o cuando se desea una primera aproximación flexible antes de pasar a métodos de ensamblaje como *Random Forest* o *Boosting*. En la asignatura, esta lógica es coherente con la progresión de contenidos de la Unidad 2, donde los árboles anteceden a Random Forest como evolución natural del enfoque.

8. Árboles versus regresión lineal

Los árboles de regresión y la regresión lineal responden a lógicas distintas. La regresión lineal asume una relación global y paramétrica entre entradas y salida; el árbol, en cambio, divide el espacio de predictores y asigna valores constantes por regiones. Si la relación real entre variables es aproximadamente lineal, la regresión lineal suele ser más eficiente y puede superar al árbol. Si la relación es altamente no lineal o está dominada por umbrales, un árbol puede representar mejor la estructura.

James et al. (2021) plantea esta comparación de manera explícita: si la relación entre predictores y respuesta está bien aproximada por un modelo lineal, la regresión lineal probablemente funcionará bien; si la relación es altamente no lineal y compleja, los árboles pueden superar a los enfoques clásicos.

Desde el punto de vista docente, esta comparación es muy útil porque ayuda a que las y los estudiantes no interpreten los modelos como competidores absolutos, sino como herramientas que deben seleccionarse según la estructura del problema, los objetivos de interpretación y la prioridad asignada a la precisión fuera de muestra.

9. Aplicaciones en problemas de predicción

Los árboles de regresión se aplican en múltiples contextos. En el sector inmobiliario, pueden predecir precios segmentando inmuebles por superficie, ubicación, antigüedad y número de habitaciones. En salud, pueden estimar tiempos de hospitalización o costos clínicos según variables demográficas y biomédicas. En operaciones, pueden modelar demanda, tiempos de servicio o niveles de consumo energético. En finanzas, pueden emplearse para estimar pérdidas, riesgo o comportamiento de clientes.

Su mayor fortaleza en aplicaciones complejas es que no requieren imponer una forma funcional única. Si la variable respuesta se comporta de manera distinta según rangos de edad, tramos de ingreso o niveles críticos de otra variable, el árbol puede capturar esos cambios estructurales mediante reglas simples y localmente interpretables.

10. Caso aplicado integrado

Considérese un problema de predicción del valor de venta de viviendas. El conjunto de datos incluye superficie construida, comuna, antigüedad, cercanía a servicios y número de habitaciones. Un árbol de regresión podría comenzar dividiendo por superficie, separando viviendas pequeñas de viviendas grandes. Dentro del grupo de viviendas grandes, podría subdividir por comuna; luego, dentro de una comuna específica, por antigüedad. Cada hoja terminal representaría un segmento relativamente homogéneo con un valor promedio de precio.

El valor pedagógico de este caso es doble. Primero, permite ver cómo el árbol segmenta progresivamente el espacio para producir predicciones más ajustadas. Segundo, facilita la interpretación de los resultados como reglas de negocio o patrones de mercado. El modelo no diría simplemente "el precio aumenta 1.200 por metro cuadrado", sino que mostraría combinaciones del tipo "si la vivienda supera cierto metraje y se ubica en una zona específica, entonces el precio esperado pertenece a un rango superior".

11. Recursos pedagógicos de la unidad

11.1. Preguntas de reflexión

- ¿Por qué un árbol de regresión puede capturar relaciones no lineales sin definir una ecuación global?
- ¿Qué diferencia existe entre una hoja terminal y un nodo de decisión?
- ¿De qué manera la profundidad del árbol afecta el equilibrio entre sesgo y varianza?
- ¿Por qué la poda puede mejorar el desempeño fuera de la muestra?
- ¿En qué situaciones preferiría un árbol de regresión por sobre una regresión lineal?

11.2. Preguntas de autoevaluación

- Define árbol de regresión.
- Explica en qué consiste la partición recursiva binaria.
- ¿Cuál es el criterio de división más habitual en árboles de regresión?
- ¿Qué se entiende por sobreajuste en un árbol de decisión?
- Explica la diferencia entre pre-poda y post-poda.
- Menciona dos ventajas y dos limitaciones del enfoque.

11.3. Glosario de conceptos fundamentales

Tabla 1. Glosario de conceptos fundamentales

Concepto	Definición
Árbol de regresión	Modelo no paramétrico que predice una variable continua mediante particiones sucesivas del espacio de entrada.
Complejidad de costo	Criterio que combina error de ajuste y penalización por número de hojas para seleccionar subárboles.
Generalización	Capacidad del modelo para mantener buen desempeño en observaciones no vistas.
Hoja terminal	Nodo final que contiene una predicción constante para las observaciones que llegan a esa región.
MSE	Error cuadrático medio; promedio de los errores al cuadrado entre valores reales y predichos.
Nodo	Punto de la estructura del árbol donde se evalúa una regla de división.
Partición recursiva binaria	Procedimiento que divide repetidamente los datos en dos subconjuntos a partir de reglas del tipo $X_j \leq c$.
Poda	Proceso de simplificar un árbol eliminando ramas poco informativas para mejorar la generalización.
Profundidad del árbol	Número de niveles o divisiones que separan la raíz de una hoja terminal.
Sobreajuste	Ajuste excesivo del modelo al conjunto de entrenamiento, que deteriora el desempeño en datos nuevos.

Fuente: elaboración propia.

Cierre

En este apartado se examinó la regresión con árboles de decisión como un recurso central dentro de la Unidad 2: Modelos de aprendizaje Supervisado – Regresión. Se explicó que los árboles construyen predicciones para variables continuas a partir de particiones sucesivas del espacio de variables, utilizando criterios de reducción del error para seleccionar divisiones, y generando predicciones constantes en hojas terminales

Referencias bibliográficas

Alpaydin, E. (2010). *Introduction to machine learning*. MIT Press.

Géron, A. (2019). *Hands-on machine learning with Scikit-Learn, Keras and TensorFlow*. O'Reilly Media.

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An introduction to statistical learning: with applications in R* (2nd ed.). Springer.

Provost, F., & Fawcett, T. (2013). *Data science for business*. O'Reilly Media.