

Regresión con Random Forest

Ruete, D. (2026). *Regresión con Random Forest* [Apunte]. Universidad Andrés Bello, Santiago, Chile.

Tabla de contenidos

Introducción	4
1. Introducción al modelo Random Forest	5
2. ¿Qué es un método de ensamblaje?	6
2.1. Definición	6
2.2. Idea de agregación.....	6
2.3. Relevancia en árboles	6
3. <i>Bagging: bootstrap aggregating</i>	7
3.1. Definición de <i>bagging</i>	7
3.2. Definición de muestra <i>bootstrap</i>	7
3.3. Efecto del <i>bagging</i> en la varianza	8
3.4. Limitación del <i>bagging</i> puro	8
4. Random Forest: aleatoriedad adicional y diversidad del bosque.....	9
4.1. Definición de Random Forest.....	9
4.2. ¿Por qué funciona?	9
4.3. Muestreo aleatorio de variables	9
5. Predicción en Random Forest para regresión.....	10
5.1. Regla de predicción	10
5.2. Interpretación del promedio.....	10
5.3. Número de árboles	10
6. Importancia de variables.....	11
6.1. Definición	11
6.2. Importancia basada en reducción de impureza	11
6.3. Importancia por permutación	11
6.4. Precauciones interpretativas	12
7. Hiperparámetros principales del modelo	13
7.1. Número de árboles (n_estimators)	13
7.2. Número de variables por división (max_features)	13
7.3. Profundidad máxima (max_depth)	13
7.4. Tamaño mínimo de hoja y tamaño mínimo de división.....	13
7.5. Estrategia docente para hiperparámetros	13
8. Sobreajuste y generalización	14
8.1. Random Forest elimina totalmente el sobreajuste?	14

8.2. <i>Out-of-bag</i> error	14
8.3. Relación con <i>bagging</i>	14
9. Comparación con otros enfoques de regresión.....	15
9.1. Comparación con regresión lineal	15
9.2. Comparación con árbol de regresión	15
9.3. Comparación con SVR y redes neuronales	15
9.4. Criterios de comparación	15
10. Caso aplicado de Random Forest para regresión	16
11. Recursos pedagógicos del apartado	17
11.1. Preguntas de reflexión.....	17
11.2. Preguntas de autoevaluación	17
11.3. Glosario de conceptos fundamentales	17
Cierre.....	19
Referencias bibliográficas	20

Introducción

La regresión con Random Forest representa un avance significativo dentro de los métodos de aprendizaje supervisado, al incorporar el enfoque de ensamblaje para mejorar la precisión y estabilidad de los modelos predictivos. A diferencia de los árboles de decisión individuales, que pueden ser altamente sensibles a variaciones en los datos, Random Forest combina múltiples árboles entrenados sobre muestras aleatorias, logrando reducir la varianza y mejorar la capacidad de generalización. Este enfoque permite abordar problemas complejos donde las relaciones entre variables no son lineales ni fácilmente modelables mediante técnicas tradicionales.

El desarrollo de este modelo se sustenta en principios clave como el *bagging* y la selección aleatoria de variables, los cuales introducen diversidad en el conjunto de modelos base. Esta diversidad es fundamental para que el promedio de las predicciones individuales produzca resultados más robustos y menos dependientes de patrones específicos del conjunto de entrenamiento. Asimismo, el modelo incorpora herramientas relevantes para el análisis, como la importancia de variables y el error *out-of-bag*, que facilitan tanto la interpretación como la evaluación del desempeño sin necesidad de particiones adicionales de los datos.

En conjunto, Random Forest se posiciona como una alternativa potente y versátil frente a otros métodos de regresión, equilibrando flexibilidad, capacidad predictiva y relativa facilidad de implementación. Su estudio permite al estudiante comprender no solo el funcionamiento de los métodos de ensamblaje, sino también desarrollar criterios para seleccionar, ajustar e interpretar modelos en función del problema analizado. De este modo, se fortalece una visión integral del modelamiento en ciencia de datos, orientada a la toma de decisiones informadas en contextos reales.


1. Introducción al modelo Random Forest

Random Forest es un método de aprendizaje supervisado basado en ensamblaje, diseñado para mejorar el desempeño de los árboles de decisión individuales. En problemas de regresión, su objetivo es predecir una variable continua utilizando un conjunto grande de árboles entrenados sobre versiones aleatorias de los datos. La predicción final del bosque se obtiene promediando las predicciones de todos los árboles.

La motivación central de Random Forest surge de una limitación conocida de los árboles de decisión: su alta varianza. Un árbol de regresión aislado puede capturar relaciones no lineales e interacciones complejas, pero pequeños cambios en los datos pueden producir árboles muy diferentes. Esta inestabilidad afecta la generalización. Random Forest reduce ese problema al combinar muchos árboles, cada uno entrenado sobre muestras distintas, de modo que el promedio final sea más estable y robusto.

Dentro de la Unidad 2: Modelos de aprendizaje Supervisado – Regresión, Random Forest representa una evolución natural después de la regresión con árboles de decisión. Si el árbol individual ofrece interpretabilidad y flexibilidad, el bosque aleatorio añade estabilidad y potencia predictiva, aunque a costa de una menor simplicidad interpretativa.

Imagen 1. Árboles individuales con alta variabilidad y predicción final obtenida por promedio del bosque



Fuente: elaboración propia.

2. ¿Qué es un método de ensamblaje?

2.1. Definición

Un método de ensamblaje es una estrategia que combina múltiples modelos base para construir una predicción final mejor que la obtenida por cada modelo por separado. La intuición es que varios modelos débiles o inestables, cuando se agregan de manera adecuada, pueden producir un predictor más preciso y con menor varianza.

2.2. Idea de agregación

En regresión, la agregación suele tomar la forma de un promedio. Si se dispone de B modelos, cada uno produce una predicción $\hat{y}^{(b)}(x)$ para una observación x . El ensamble se define como el promedio de todas esas predicciones. Este promedio suaviza errores individuales y reduce el efecto de decisiones demasiado particulares de un modelo aislado.

2.3. Relevancia en árboles

Los árboles de decisión son candidatos ideales para métodos de ensamblaje porque, aun cuando son potentes para capturar no linealidad, suelen ser inestables. Esa inestabilidad implica alta varianza: distintos conjuntos de entrenamiento pueden producir árboles muy diferentes. Al promediar muchos árboles, Random Forest explota esa diversidad para mejorar la generalización.

3. *Bagging: bootstrap aggregating*

3.1. Definición de *bagging*


Bagging, abreviación de *bootstrap aggregating*, es un método de ensamblaje que consiste en generar múltiples muestras bootstrap del conjunto de entrenamiento, entrenar un modelo en cada una de ellas y luego combinar sus predicciones. En regresión, la combinación se realiza mediante un promedio.

3.2. Definición de muestra *bootstrap*

Una muestra *bootstrap* se obtiene seleccionando observaciones del conjunto original con reemplazo. Esto significa que una misma observación puede aparecer varias veces en la muestra generada, mientras que otras observaciones pueden quedar fuera. Si el conjunto original tiene n observaciones, cada muestra *bootstrap* también tendrá n observaciones, pero con repeticiones.

En términos pedagógicos, el *bootstrap* introduce variación controlada en los datos de entrenamiento. Cada árbol ve una versión ligeramente distinta del mismo problema. Esa diversidad es precisamente lo que hace útil el promedio posterior.

Imagen 2. Esquema de *bagging*: datos originales, muestras *bootstrap*, árboles individuales y promedio final



Fuente: elaboración propia.

3.3. Efecto del *bagging* en la varianza

Si los árboles individuales son variables, el promedio de muchos árboles reduce la variabilidad total de la predicción. Esta idea puede entenderse por analogía con la media muestral: promediar observaciones independientes reduce la dispersión respecto de una observación individual. De modo similar, promediar árboles reduce la sensibilidad del modelo a perturbaciones del conjunto de entrenamiento.

3.4. Limitación del *bagging* puro

Bagging mejora el desempeño de los árboles, pero si todos los árboles se parecen demasiado entre sí, la ganancia puede ser menor de lo esperado. Por ejemplo, si una variable muy fuerte domina siempre la primera división, muchos árboles *bootstrap* tenderán a parecerse. Random Forest introduce una capa adicional de aleatoriedad precisamente para reducir esa correlación entre árboles.

4. Random Forest: aleatoriedad adicional y diversidad del bosque

4.1. Definición de Random Forest

Random Forest es una extensión de *bagging* en la que, además de usar muestras *bootstrap*, se restringe aleatoriamente el conjunto de variables candidatas en cada división del árbol. De esta forma, no todas las variables compiten en cada nodo, sino solo un subconjunto aleatorio de ellas.

4.2. ¿Por qué funciona?

La lógica de Random Forest se basa en dos mecanismos complementarios: reducir la varianza mediante el promedio de múltiples árboles y reducir la correlación entre esos árboles introduciendo aleatoriedad en las divisiones. Si los árboles son menos parecidos entre sí, el promedio final gana diversidad y puede ofrecer una predicción más robusta.

4.3. Muestreo aleatorio de variables

En cada nodo, el algoritmo selecciona aleatoriamente m predictores entre los p predictores disponibles. Solo ese subconjunto compite para encontrar la mejor división. Esta estrategia evita que una variable dominante monopolice todas las decisiones tempranas del árbol y permite que otras variables también participen en la estructura del modelo.

Desde la docencia, este punto es crucial: Random Forest no es simplemente “muchos árboles”. Es “muchos árboles + *bootstrap* + selección aleatoria de variables en cada división”. Esa combinación es la que explica su buen desempeño predictivo.

5. Predicción en Random Forest para regresión


5.1. Regla de predicción

En regresión, cada árbol del bosque entrega una predicción continua para la observación nueva. La salida final de Random Forest es el promedio de las predicciones de los B árboles del bosque. Si un árbol predice 120, otro 125 y otro 122, la predicción agregada será el promedio de esos valores.

5.2. Interpretación del promedio

El promedio no solo suaviza la predicción. También expresa el principio estadístico de estabilización por agregación. Un árbol puede sobrestimar, otro subestimar, y el promedio de muchos árboles tiende a neutralizar parte de esos errores individuales. Esta es una de las razones por las que Random Forest suele superar a un árbol de regresión aislado.

Imagen 3. Evolución del error al aumentar el número de árboles del bosque



Fuente: elaboración propia.

5.3. Número de árboles

Uno de los hiperparámetros más visibles del modelo es el número total de árboles. En general, a medida que aumenta el número de árboles, la predicción se estabiliza y el error de validación se vuelve menos variable. A diferencia de otros modelos, incrementar el número de árboles no suele provocar sobreajuste severo; más bien, tiende a estabilizar el desempeño, aunque con mayor costo computacional.

6. Importancia de variables

6.1. Definición

La importancia de variables es un mecanismo para cuantificar cuánto contribuye cada predictor al desempeño del bosque. En términos generales, una variable es importante si sus divisiones reducen con frecuencia el error o si al permutar sus valores el desempeño del modelo empeora de forma significativa.


6.2. Importancia basada en reducción de impureza

Una forma de medir importancia es acumular, a través de todos los árboles, cuánto disminuye el error cuadrático cada vez que una variable es utilizada en una división. Si una variable aparece repetidamente en nodos que mejoran mucho la homogeneidad local, su importancia acumulada será mayor.

6.3. Importancia por permutación

Otra estrategia consiste en permutar aleatoriamente los valores de una variable y observar cuánto empeora la predicción del modelo. Si al romper la relación entre esa variable y la respuesta el error aumenta de forma importante, se concluye que la variable tenía un rol predictivo relevante.

Imagen 4. Ejemplo de importancia relativa de variables en un problema de regresión



Fuente: elaboración propia.

6.4. Precauciones interpretativas

La importancia de variables no debe confundirse automáticamente con causalidad. Que una variable sea importante para predecir no significa necesariamente que cause la respuesta. Además, variables correlacionadas pueden compartir relevancia, lo que dificulta su separación conceptual. Aun así, la importancia de variables es una herramienta pedagógica y práctica muy valiosa para interpretar el bosque y apoyar decisiones sobre selección de predictores.

7. Hiperparámetros principales del modelo

7.1. Número de árboles (n_estimators)

Este hiperparámetro define cuántos árboles compondrán el bosque. Un valor mayor suele mejorar la estabilidad del modelo, aunque incrementa el tiempo de entrenamiento y predicción.

7.2. Número de variables por división (max_features)

Este parámetro controla cuántas variables compiten en cada nodo. Si se elige un valor pequeño, los árboles serán más diversos pero cada división tendrá menos opciones. Si se elige un valor grande, los árboles tenderán a parecerse más entre sí. El equilibrio entre diversidad y capacidad de cada árbol es uno de los aspectos clave del modelo.

7.3. Profundidad máxima (max_depth)

Aunque Random Forest tolera árboles relativamente profundos, controlar la profundidad puede reducir costo computacional y prevenir estructuras excesivamente específicas. La profundidad máxima fija el número máximo de niveles permitidos en cada árbol.

7.4. Tamaño mínimo de hoja y tamaño mínimo de división

Estos parámetros establecen cuántas observaciones mínimas debe contener un nodo para ser dividido y cuántas debe contener una hoja terminal. Valores más altos producen árboles más suaves y menos sensibles al ruido; valores más bajos permiten árboles más detallados y flexibles.

7.5. Estrategia docente para hiperparámetros

En formación de posgrado, no basta con nombrar hiperparámetros. Es importante comprender qué problema resuelve cada uno. Algunos controlan diversidad, otra complejidad, otros costos computacionales. La selección de hiperparámetros debe entenderse como un proceso de calibración entre ajuste, generalización, interpretabilidad y eficiencia.

8. Sobreajuste y generalización

8.1. Random Forest elimina totalmente el sobreajuste?

Random Forest reduce de manera muy importante el riesgo de sobreajuste en comparación con un árbol individual, pero no lo elimina por completo. Puede seguir existiendo sobreajuste si el modelo se calibra mal, si los datos contienen mucho ruido, si el número de predictores irrelevantes es muy alto o si la evaluación del desempeño no se realiza correctamente.

8.2. *Out-of-bag* error

Una ventaja notable del método es el uso del error *out-of-bag* (OOB). Como cada árbol se entrena con una muestra *bootstrap*, una fracción de las observaciones originales queda fuera de esa muestra. Esas observaciones pueden utilizarse como validación interna para estimar el error sin necesidad de una partición externa adicional. El OOB error es, por tanto, una herramienta muy útil para monitorear generalización y comparar configuraciones del modelo.

8.3. Relación con *bagging*

El principio de generalización en Random Forest depende de la misma intuición de *bagging*: promediar modelos reduce varianza. La selección aleatoria de variables refuerza ese efecto al disminuir la correlación entre árboles. Esta combinación explica por qué el bosque suele comportarse mejor que un árbol individual en términos de error fuera de muestra.

9. Comparación con otros enfoques de regresión

9.1. Comparación con regresión lineal

La regresión lineal ofrece una estructura global, paramétrica y altamente interpretable. Random Forest, en cambio, es flexible, no lineal y basado en ensamblaje. Si la relación entre variables y respuesta es aproximadamente lineal, la regresión lineal puede ser suficiente e incluso preferible por simplicidad. Si la relación es compleja, con interacciones y umbrales, Random Forest suele capturar mejor el patrón.

9.2. Comparación con árbol de regresión

El árbol individual es más interpretable que el bosque, porque sus reglas pueden representarse y leerse directamente. Sin embargo, Random Forest normalmente mejora el desempeño predictivo y la estabilidad. En términos docentes, puede enseñarse el árbol individual como base conceptual y Random Forest como su extensión robusta.

9.3. Comparación con SVR y redes neuronales

Frente a modelos como *Support Vector Regression* o redes neuronales, Random Forest suele tener la ventaja de requerir menos ajuste fino inicial y ofrecer mecanismos internos de importancia de variables. No obstante, en ciertos problemas muy específicos, otros enfoques pueden superarlo en precisión. La elección del modelo no debe hacerse por moda, sino por desempeño empírico y adecuación al problema.

9.4. Criterios de comparación

Al comparar Random Forest con otros modelos de regresión, conviene considerar al menos cuatro dimensiones: error de predicción (MSE, RMSE, MAE), estabilidad fuera de muestra, interpretabilidad y costo computacional. Un modelo puede ser muy preciso, pero poco interpretable, o muy interpretable pero poco flexible. La comparación debe ser multidimensional.

10. Caso aplicado de Random Forest para regresión

Supón un problema de predicción del precio de viviendas con variables como superficie, ubicación, cantidad de habitaciones, antigüedad, cercanía a transporte y nivel socioeconómico del barrio. Un modelo lineal podría capturar tendencias promedio, pero le costaría representar interacciones complejas. Un árbol individual podría segmentar el espacio por umbrales, pero sería inestable. Random Forest permite construir muchos árboles sobre muestras *bootstrap* y promediar sus predicciones, mejorando la estabilidad del resultado.

En este escenario, la importancia de variables podría mostrar que superficie y ubicación explican buena parte de la variación del precio, mientras que antigüedad y distancia a servicios tienen un efecto secundario. El error OOB permitiría monitorear el desempeño sin necesidad de reservar demasiados datos para validación. Además, la comparación con regresión lineal podría revelar que el bosque mejora la predicción cuando el mercado inmobiliario presenta comportamientos segmentados y no lineales.

11. Recursos pedagógicos del apartado

11.1. Preguntas de reflexión

- ¿Por qué Random Forest reduce la varianza respecto de un árbol individual?
- ¿Qué rol cumple el *bootstrap* en la construcción del bosque?
- ¿Por qué limitar aleatoriamente las variables candidatas en cada nodo mejora la diversidad del ensamblaje?
- ¿Cuándo podría preferirse una regresión lineal por sobre Random Forest, aun si el bosque predice mejor?
- ¿Qué riesgos existen al interpretar la importancia de variables como causalidad?

11.2. Preguntas de autoevaluación

- Define Random Forest para regresión.
- Explique la diferencia entre *bagging* y Random Forest.
- ¿Qué es una muestra *bootstrap*?
- ¿Qué se entiende por error *out-of-bag*?
- Menciona tres hiperparámetros importantes del modelo y explique su función.
- Indica dos criterios útiles para comparar Random Forest con otros modelos de regresión.

11.3. Glosario de conceptos fundamentales

Tabla 1. Glosario de conceptos fundamentales

Concepto	Definición
<i>Bagging</i>	Técnica de <i>bootstrap aggregating</i> que entrena múltiples modelos sobre muestras con reemplazo y promedia sus predicciones.
<i>Bootstrap</i>	Procedimiento de remuestreo con reemplazo a partir del conjunto original de datos.
Ensamblaje	Combinación de varios modelos base para construir una predicción final más robusta.
Generalización	Capacidad del modelo para mantener buen desempeño en datos no vistos.
Importancia de variables	Medida que cuantifica cuánto contribuye cada predictor al desempeño del modelo.
max_features	Número de variables candidatas consideradas en cada división del árbol.
n_estimators	Número total de árboles del bosque.
<i>Out-of-bag error</i>	Estimación interna del error obtenida usando observaciones que quedaron fuera de la muestra <i>bootstrap</i> de cada árbol.
Random Forest	Método de ensamblaje que combina múltiples árboles de decisión entrenados sobre muestras <i>bootstrap</i> y subconjuntos aleatorios de variables.
Varianza del modelo	Sensibilidad del predictor a cambios en los datos de entrenamiento.

Fuente: elaboración propia.

Cierre

En este apartado se abordó de manera integral la regresión con Random Forest como un método de aprendizaje supervisado basado en ensamblaje, destacando su capacidad para superar las limitaciones de los árboles de decisión individuales. Se analizó cómo la combinación de múltiples árboles, junto con el uso de muestras *bootstrap* y la selección aleatoria de variables, permite reducir la varianza del modelo, incrementar la diversidad del bosque y mejorar significativamente la estabilidad y precisión de las predicciones.

Asimismo, se profundizó en elementos clave para su aplicación práctica, como la interpretación de la importancia de variables, la calibración de hiperparámetros y el uso del error *out-of-bag* como mecanismo de validación interna. Estos componentes no solo fortalecen el desempeño del modelo, sino que también aportan herramientas relevantes para su análisis crítico, facilitando decisiones informadas en contextos reales donde la complejidad de los datos exige enfoques más flexibles.

En conjunto, el estudio de Random Forest consolida la comprensión de los métodos de ensamblaje dentro del aprendizaje automático, permitiendo al estudiante articular implementación, evaluación e interpretación en un mismo marco analítico. De este modo, se promueve una visión aplicada del modelamiento predictivo, donde la elección del modelo responde tanto a criterios técnicos como a la naturaleza del problema, fortaleciendo competencias clave en ciencia de datos y analítica avanzada.

Referencias bibliográficas

Alpaydin, E. (2010). *Introduction to machine learning*. MIT Press.

Géron, A. (2019). *Hands-on machine learning with Scikit-Learn, Keras and TensorFlow*. O'Reilly Media.

Provost, F., & Fawcett, T. (2013). *Data science for business*. O'Reilly Media.

Witten, D., Hastie, T., & Tibshirani, R. (2021). *An introduction to statistical learning: with applications in R* (2nd ed.). Springer.