

Regresión con redes neuronales artificiales

Ruete, D. (2026). *Regresión con redes neuronales artificiales* [Apunte].
Universidad Andrés Bello, Santiago, Chile.

Tabla de contenidos

Introducción	4
1. Introducción a las redes neuronales para regresión	5
2. Arquitectura básica de una red neuronal	6
2.1. Definición de arquitectura	6
2.2. Capa de entrada	6
2.3. Capas ocultas	6
2.4. Capa de salida en regresión	6
2.5. Pesos y sesgos	6
3. Funciones de activación	7
3.1. Definición	7
3.2. ReLU	7
3.3. Tanh y sigmoide	7
3.4. Activación en la salida	7
4. Propagación hacia adelante y proceso de predicción	8
4.1. Forward propagation	8
4.2. Interpretación funcional	8
5. Función de pérdida y proceso de entrenamiento	9
5.1. Definición de función de pérdida	9
5.2. Objetivo del entrenamiento	9
5.3. Descenso del gradiente	9
5.4. Backpropagation	9
6. Sobreajuste en redes neuronales	10
6.1. Definición	10
6.2. Señales de sobreajuste	10
6.3. Relación con la capacidad del modelo	10
7. Regularización	11
7.1. Definición	11
7.2. L2 o weight decay	11
7.3. Dropout	11
7.4. Early stopping	11
7.5. Batch normalization y otras prácticas	11
8. Consideraciones prácticas para entrenar redes neuronales en regresión	12

8.1. Escalamiento de variables	12
8.2. Tamaño del conjunto de datos.....	12
8.3. Selección de arquitectura	12
8.4. Hiperparámetros	12
8.5. Costo computacional	12
9. ¿Cuándo usar redes neuronales en regresión?.....	13
10. Caso aplicado en predicción de variables continuas.....	14
11. Recursos pedagógicos del apartado	15
11.1. Preguntas de reflexión.....	15
11.2. Preguntas de autoevaluación	15
11.3. Glosario de conceptos fundamentales	15
Cierre.....	17
Referencias bibliográficas	18

Introducción

La regresión con redes neuronales artificiales representa uno de los enfoques más flexibles y potentes dentro del aprendizaje supervisado para la predicción de variables continuas. Inspiradas en la estructura de sistemas neuronales biológicos, estas redes permiten modelar relaciones complejas mediante la combinación de múltiples capas de procesamiento que transforman progresivamente la información de entrada. A diferencia de los modelos tradicionales, que requieren especificar explícitamente la forma funcional, las redes neuronales aprenden directamente de los datos, construyendo aproximaciones capaces de capturar no linealidades e interacciones de alta complejidad.

El funcionamiento de estas redes se basa en la interacción entre neuronas, pesos, sesgos y funciones de activación, que en conjunto permiten generar representaciones intermedias cada vez más abstractas. El proceso de entrenamiento, apoyado en algoritmos como el descenso del gradiente y la retropropagación, ajusta los parámetros del modelo para minimizar una función de pérdida. Este enfoque convierte el aprendizaje en un problema de optimización, donde la calidad del resultado depende tanto de la arquitectura elegida como de la correcta calibración de hiperparámetros y del tratamiento adecuado de los datos.

En el contexto de los modelos de regresión, las redes neuronales se posicionan como una alternativa avanzada frente a métodos como la regresión lineal, los árboles de decisión, Random Forest o SVR. Su uso resulta especialmente relevante en problemas donde la complejidad estructural de los datos supera la capacidad de modelos más simples. No obstante, su implementación exige un enfoque cuidadoso que considere aspectos como el sobreajuste, la regularización y el costo computacional, promoviendo así una comprensión integral del modelamiento predictivo en ciencia de datos.


1. Introducción a las redes neuronales para regresión

Las redes neuronales artificiales constituyen una familia de modelos de aprendizaje supervisado inspirados, de manera abstracta, en la organización de neuronas interconectadas. En problemas de regresión, su objetivo es aproximar una función que permita predecir una variable continua a partir de uno o más predictores. A diferencia de la regresión lineal, que impone una estructura funcional explícita, las redes neuronales aprenden representaciones intermedias de los datos y construyen funciones altamente flexibles capaces de capturar patrones no lineales e interacciones complejas.

Su atractivo en regresión radica en la capacidad de modelar relaciones que no se describen adecuadamente con una ecuación simple. Esta flexibilidad, sin embargo, introduce desafíos: entrenamiento iterativo, necesidad de seleccionar hiperparámetros, sensibilidad a la escala de variables y riesgo de sobreajuste. Por ello, el aprendizaje de redes neuronales no debe reducirse a una descripción superficial de capas y conexiones, sino entenderse como un problema de optimización y regularización.

En la Unidad 2: Modelos de aprendizaje Supervisado – Regresión, las redes neuronales aparecen como una alternativa avanzada a modelos lineales, árboles, Random Forest y SVR. Su estudio amplía la comprensión de los estudiantes sobre modelos capaces de aprender funciones no lineales complejas, especialmente en contextos donde la riqueza del patrón subyacente supera lo que otros enfoques capturan con facilidad.

Imagen 1. Arquitectura básica de una red neuronal multicapa para una tarea de regresión



Fuente: elaboración propia.

2. Arquitectura básica de una red neuronal

2.1. Definición de arquitectura

La arquitectura de una red neuronal describe la forma en que se organizan sus unidades de procesamiento, conocidas como neuronas, y las conexiones entre ellas. En términos generales, una red neuronal para regresión se compone de una capa de entrada, una o más capas ocultas y una capa de salida.

2.2. Capa de entrada

La capa de entrada recibe las variables predictoras del problema. Si el modelo utiliza p variables de entrada, la capa de entrada tendrá p nodos, cada uno asociado a una característica del conjunto de datos. Esta capa no transforma la información por sí misma; su función es distribuirla hacia las capas siguientes.

2.3. Capas ocultas

Las capas ocultas son el núcleo de la capacidad expresiva de la red. Cada neurona recibe una combinación ponderada de las salidas de la capa anterior, añade un sesgo y luego aplica una función de activación. Gracias a este mecanismo, la red puede construir representaciones intermedias progresivamente más abstractas. Cuantas más capas y neuronas contengan, mayor será la capacidad del modelo para aproximar funciones complejas.

2.4. Capa de salida en regresión

En tareas de regresión, la capa de salida suele tener una única neurona cuando se desea predecir una sola variable continua. A diferencia de problemas de clasificación, en regresión normalmente no se utiliza una función de activación acotada en la salida, ya que el objetivo es permitir valores continuos en un rango amplio.

2.5. Pesos y sesgos

Las conexiones entre neuronas poseen pesos, que cuantifican la fuerza de la relación entre unidades. Además, cada neurona incluye un sesgo o bias que desplaza la combinación lineal previa a la activación. El aprendizaje de la red consiste precisamente en ajustar pesos y sesgos para que la predicción final minimice una función de pérdida sobre los datos de entrenamiento.

3. Funciones de activación

3.1. Definición

Una función de activación es una transformación no lineal aplicada a la combinación ponderada de entradas de una neurona. Sin activaciones no lineales, incluso una red con múltiples capas se reduciría a una transformación lineal global. Las funciones de activación son, por tanto, las responsables de la capacidad de la red para modelar relaciones complejas.


3.2. ReLU

La función ReLU, definida como $\max(0, z)$, es una de las más utilizadas en capas ocultas por su simplicidad y eficiencia computacional. ReLU permite activar solo valores positivos y anula los negativos, lo que favorece el entrenamiento en redes profundas y reduce ciertos problemas asociados a activaciones saturadas.

3.3. Tanh y sigmoide

La función tangente hiperbólica ($\tanh$) y la función sigmoide fueron ampliamente utilizadas en etapas tempranas del desarrollo de redes neuronales. Ambas comprimen la señal en rangos acotados, lo que puede ser útil en algunos contextos, aunque también puede dificultar el flujo de gradientes en redes profundas. Su valor pedagógico sigue siendo alto porque ilustran cómo la activación altera la geometría de la representación.

Imagen 2. Ejemplos de funciones de activación frecuentes en redes neuronales



Fuente: elaboración propia.

3.4. Activación en la salida

En regresión, la salida suele ser lineal o identidad, pues se requiere libertad para predecir valores continuos no acotados. Esta decisión diferencia a las redes de regresión de las redes para clasificación, donde la capa de salida acostumbra a utilizar sigmoide o softmax para representar probabilidades.

4. Propagación hacia adelante y proceso de predicción


4.1. Forward propagation

La propagación hacia adelante, o forward propagation, es el proceso mediante el cual una observación recorre la red desde la capa de entrada hasta la salida. En cada neurona, las entradas se combinan linealmente con sus pesos, se añade el sesgo y se aplica la función de activación correspondiente. El resultado se transmite a la siguiente capa hasta obtener una predicción final.

4.2. Interpretación funcional

Desde una perspectiva matemática, una red neuronal multicapa es una composición de funciones lineales y no lineales. Cada capa transforma la representación de los datos, permitiendo que la salida final dependa de una jerarquía de transformaciones. Esta composición explica por qué las redes pueden aproximar funciones altamente complejas.

Imagen 3. Aproximación no lineal en una tarea de regresión con red neuronal



Fuente: elaboración propia.

5. Función de pérdida y proceso de entrenamiento

5.1. Definición de función de pérdida

La función de pérdida cuantifica qué tan lejos están las predicciones del modelo respecto de los valores reales. En regresión, una de las opciones más comunes es el error cuadrático medio (MSE), que promedia el cuadrado de las diferencias entre y y $\hat{y}$. También pueden utilizarse MAE, RMSE u otras variantes según el problema.

5.2. Objetivo del entrenamiento

Entrenar una red neuronal significa encontrar el conjunto de pesos y sesgos que minimiza la función de pérdida sobre los datos de entrenamiento. Este problema de optimización se resuelve de manera iterativa, ajustando gradualmente los parámetros mediante algoritmos basados en gradientes.


5.3. Descenso del gradiente

El descenso del gradiente actualiza los parámetros en la dirección opuesta al gradiente de la pérdida, pues esa es la dirección local de mayor reducción del error. En la práctica se utilizan variantes como stochastic gradient descent, Adam o RMSprop, que mejoran estabilidad y velocidad de convergencia.

5.4. Backpropagation

La retropropagación, o backpropagation, es el procedimiento que permite calcular eficientemente cómo contribuye cada peso al error final. Propaga el gradiente desde la salida hacia atrás, capa por capa, usando la regla de la cadena. Este algoritmo es fundamental porque hace viable el entrenamiento de redes multicapa.

Imagen 4. Evolución de la pérdida de entrenamiento y validación durante el aprendizaje



Fuente: elaboración propia.

6. Sobreajuste en redes neuronales

6.1. Definición

El sobreajuste ocurre cuando la red neuronal aprende en exceso los detalles del conjunto de entrenamiento, incluyendo ruido o particularidades no generalizables, y por ello pierde desempeño en datos nuevos. Este riesgo aumenta con arquitecturas muy flexibles, gran número de parámetros y entrenamiento prolongado sin control.

6.2. Señales de sobreajuste

Una señal clásica es la divergencia entre pérdida de entrenamiento y pérdida de validación. Mientras la pérdida de entrenamiento continúa disminuyendo, la pérdida de validación deja de mejorar e incluso aumenta. Esta dinámica indica que la red está adaptándose demasiado al conjunto observado y empeorando su generalización.

6.3. Relación con la capacidad del modelo

Cuantas más capas y neuronas tengan la red, mayor es su capacidad representacional. Esa capacidad es valiosa, pero también puede transformarse en una fuente de sobreajuste si no se acompaña de regularización, tamaño de muestra adecuado y control del entrenamiento.

7. Regularización

7.1. Definición

La regularización es el conjunto de estrategias destinadas a controlar la complejidad efectiva de la red para favorecer la generalización. Su objetivo no es eliminar flexibilidad, sino impedir que esa flexibilidad se traduzca en ajuste excesivo a la muestra.

7.2. L2 o weight decay

La regularización L2 penaliza pesos muy grandes añadiendo a la función de pérdida un término proporcional a la suma de cuadrados de los pesos. Esto favorece soluciones más suaves y distribuidas, evitando que la red dependa excesivamente de conexiones particulares.

7.3. Dropout

Dropout consiste en desactivar aleatoriamente una fracción de neuronas durante el entrenamiento. Esta estrategia fuerza a la red a no depender demasiado de rutas específicas de información y promueve representaciones más robustas. Aunque se usa con frecuencia en clasificación, también puede ser útil en regresión.

7.4. Early stopping

El early stopping detiene el entrenamiento cuando la pérdida de validación deja de mejorar. Es una técnica especialmente práctica y efectiva para redes neuronales, pues evita seguir optimizando sobre patrones demasiado particulares del conjunto de entrenamiento.

7.5. Batch normalization y otras prácticas

Otras técnicas, como batch normalization, pueden estabilizar el entrenamiento y mejorar la propagación de gradientes. No obstante, su uso debe justificarse pedagógicamente según la complejidad del curso y el nivel de profundidad esperado en la unidad.

8. Consideraciones prácticas para entrenar redes neuronales en regresión

8.1. Escalamiento de variables

El escalamiento de variables es altamente recomendable en redes neuronales. Dado que el entrenamiento depende de gradientes y optimización numérica, variables en escalas muy diferentes pueden dificultar la convergencia. La estandarización suele ser una opción adecuada, ya que centra y reescala las variables para facilitar el aprendizaje.

8.2. Tamaño del conjunto de datos

Las redes neuronales suelen beneficiarse de mayores cantidades de datos que modelos más simples. Aunque pueden funcionar en muestras moderadas, su verdadero potencial aparece cuando disponen de suficiente información para aprender patrones complejos sin depender excesivamente de regularización.

8.3. Selección de arquitectura

No existe una arquitectura universalmente óptima. El número de capas, el número de neuronas por capa, la función de activación y la estrategia de regularización deben elegirse en función del problema, del tamaño del conjunto de datos y del equilibrio deseado entre capacidad e interpretabilidad.

8.4. Hiperparámetros

Entre los hiperparámetros relevantes se encuentran la tasa de aprendizaje, el número de épocas, el tamaño del batch, la arquitectura, el optimizador y la intensidad de regularización. La selección de estos componentes suele apoyarse en validación cruzada, conjunto de validación o estrategias sistemáticas de búsqueda.

8.5. Costo computacional

Frente a modelos lineales o árboles, las redes neuronales pueden exigir mayor costo computacional, especialmente a medida que aumenta la profundidad del modelo. Este factor debe considerarse al comparar alternativas dentro de la Unidad 2.

9. ¿Cuándo usar redes neuronales en regresión?

Las redes neuronales son especialmente competitivas cuando el problema presenta relaciones altamente no lineales, interacciones complejas y suficiente volumen de datos. En escenarios donde la estructura subyacente es demasiado rica para ser capturada por una regresión lineal, un árbol aislado o incluso un SVR con kernel fijo, una red neuronal bien entrenada puede ofrecer ventajas sustantivas.

Sin embargo, su uso no siempre es la mejor decisión. Si el conjunto de datos es pequeño, si la interpretabilidad es prioritaria o si una estructura simple ya describe razonablemente el fenómeno, modelos más parsimoniosos pueden ser preferibles. Desde la docencia, esto es esencial: no se trata de presentar las redes como el "modelo superior", sino como una alternativa adecuada en ciertos escenarios y menos conveniente en otros.

10. Caso aplicado en predicción de variables continuas

Considera un problema de predicción de demanda horaria de energía eléctrica usando variables como temperatura, humedad, hora del día, día de la semana, nivel de actividad industrial y eventos especiales. La relación entre estos predictores y la demanda es compleja, no lineal y altamente interactiva. Una red neuronal multicapa puede aprender representaciones internas que combinen estas variables de forma más flexible que una regresión lineal tradicional.

En este caso, la capa de entrada recibe los predictores; una o más capas ocultas aplican transformaciones no lineales; la salida entrega una estimación continua de la demanda. El entrenamiento se realiza minimizando una función de pérdida como MSE, mientras que la validación monitorea la generalización. Técnicas como early stopping y regularización L2 ayudan a controlar el sobreajuste.

11. Recursos pedagógicos del apartado

11.1. Preguntas de reflexión

- ¿Por qué una red neuronal sin funciones de activación no lineales pierde gran parte de su capacidad expresiva?
- ¿Qué diferencia existe entre pesos y sesgos dentro de una neurona?
- ¿Por qué backpropagation es fundamental para el entrenamiento de redes multicapa?
- ¿De qué manera el early stopping ayuda a controlar el sobreajuste?
- ¿En qué situaciones preferiría una red neuronal por sobre Random Forest o SVR?

11.2. Preguntas de autoevaluación

- Define red neuronal artificial aplicada a regresión.
- Explica la función de una capa oculta.
- ¿Qué es una función de activación y por qué se utiliza?
- Define función de pérdida en una tarea de regresión.
- ¿Qué es backpropagation?
- Menciona dos técnicas de regularización aplicables a redes neuronales.

11.3. Glosario de conceptos fundamentales

Tabla 1. Glosario de conceptos fundamentales

Concepto	Definición
Backpropagation	Algoritmo que calcula gradientes de la pérdida respecto de los parámetros de la red.
Capa de entrada	Conjunto de nodos que recibe las variables predictoras del problema.
Capa oculta	Capa intermedia que transforma la información mediante combinaciones lineales y funciones de activación.
Early stopping	Estrategia que detiene el entrenamiento cuando la pérdida de validación deja de mejorar.
Función de activación	Transformación no lineal aplicada a la salida de una neurona.
Función de pérdida	Medida que cuantifica el error entre valores reales y predichos.
Peso	Parámetro que cuantifica la influencia de una conexión entre neuronas.
Regularización	Conjunto de técnicas destinadas a controlar la complejidad del modelo y mejorar generalización.
Red neuronal artificial	Modelo de aprendizaje supervisado compuesto por capas de neuronas interconectadas que aprenden una función de predicción.
Sesgo	Parámetro adicional que desplaza la combinación lineal en una neurona.

Fuente: elaboración propia.

Cierre

En este apartado se desarrollaron los fundamentos de las redes neuronales artificiales aplicadas a problemas de regresión, destacando su capacidad para aproximar funciones complejas mediante arquitecturas multicapa y transformaciones no lineales. Se analizó el rol de los componentes esenciales del modelo, como las capas, los pesos, los sesgos y las funciones de activación, así como el proceso de entrenamiento basado en la optimización de una función de pérdida mediante algoritmos de descenso del gradiente y retropropagación.

Asimismo, se abordaron desafíos clave asociados a este tipo de modelos, particularmente el riesgo de sobreajuste derivado de su alta capacidad representacional. En este sentido, se revisaron diversas estrategias de regularización, como L2, dropout y early stopping, junto con la importancia del escalamiento de variables y la correcta selección de hiperparámetros. Estos elementos son fundamentales para lograr un equilibrio adecuado entre ajuste y capacidad de generalización en contextos reales.

En conjunto, las redes neuronales se consolidan como una herramienta poderosa dentro del análisis de regresión, especialmente en escenarios caracterizados por relaciones altamente no lineales y gran complejidad estructural. Su estudio permite al estudiante integrar conceptos de optimización, representación de datos y aprendizaje automático, fortaleciendo una perspectiva crítica sobre cuándo y cómo aplicar estos modelos en función de las características del problema, los datos disponibles y los objetivos del análisis.

Referencias bibliográficas

Alpaydin, E. (2010). *Introduction to machine learning*. MIT Press.

Géron, A. (2019). *Hands-on machine learning with Scikit-Learn, Keras and TensorFlow*. O'Reilly Media.

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An introduction to statistical learning: with applications in R* (2nd ed.). Springer.

Provost, F., & Fawcett, T. (2013). *Data science for business*. O'Reilly Media.