



**MCDI504**

**MACHINE LEARNING I**

**AVANCE DEL PROYECTO — FASE 2:**

**IMPLEMENTACIÓN DE MODELOS DE REGRESIÓN**

**SUPERVISADA**

Integrantes: Alana Bermúdez · Gonzalo Mansilla · Eduardo Villalón

Curso: MCDI504 · Machine Learning I · Grupo 7

Docente: David Ruete

Fecha: 16 de agosto de 2026

## ÍNDICE GENERAL

|                                                                         |    |
|-------------------------------------------------------------------------|----|
| <a href="#">Introducción y contextualización</a>                        | 3  |
| <a href="#">Descripción del conjunto de datos y preprocesamiento</a>    | 3  |
| <a href="#">Calidad y tratamiento de datos</a>                          | 4  |
| <a href="#">Selección, partición y prevención de fuga</a>               | 4  |
| <a href="#">Análisis exploratorio inicial</a>                           | 5  |
| <a href="#">Modelo de regresión lineal simple</a>                       | 6  |
| <a href="#">Árbol de decisión para regresión</a>                        | 6  |
| <a href="#">Red neuronal MLP para regresión</a>                         | 8  |
| <a href="#">Evaluación de modelos de regresión</a>                      | 8  |
| <a href="#">Comparación de modelos</a>                                  | 10 |
| <a href="#">Elección analítica fundamentada</a>                         | 10 |
| <a href="#">Notebook F2_Regresion.ipynb y documentación del proceso</a> | 11 |
| <a href="#">Estructura del repositorio</a>                              | 11 |
| <a href="#">Conclusiones</a>                                            | 12 |
| <a href="#">Uso de fuentes, citación y referencias</a>                  | 12 |
| <a href="#">Anexos</a>                                                  | 13 |
| <a href="#">Anexo A. Resultados complementarios exportados</a>          | 13 |
| <a href="#">Anexo B. Lista de verificación de la rúbrica</a>            | 14 |

## ÍNDICE DE FIGURAS

|                                                                                                |    |
|------------------------------------------------------------------------------------------------|----|
| <a href="#">Figura 1. Relación entre largo y ancho del pétalo, diferenciada por especie</a>    | 5  |
| <a href="#">Figura 2. Estructura del árbol de decisión entrenado</a>                           | 7  |
| <a href="#">Figura 3. Comparación de MSE, RMSE y <math>R^2</math> en el conjunto de prueba</a> | 9  |
| <a href="#">Figura 4. Curvas de predicción y valores reales del conjunto de prueba</a>         | 10 |

## ÍNDICE DE TABLAS

|                                                                                      |    |
|--------------------------------------------------------------------------------------|----|
| <a href="#">Tabla 1. Síntesis del problema analítico</a>                             | 3  |
| <a href="#">Tabla 2. Variables del conjunto de datos y función analítica</a>         | 4  |
| <a href="#">Tabla 3. Distribución de las observaciones en entrenamiento y prueba</a> | 4  |
| <a href="#">Tabla 4. Configuración de la regresión lineal simple</a>                 | 6  |
| <a href="#">Tabla 5. Métricas de la regresión lineal simple</a>                      | 6  |
| <a href="#">Tabla 6. Hiperparámetros del árbol de decisión</a>                       | 6  |
| <a href="#">Tabla 7. Métricas del árbol de decisión</a>                              | 7  |
| <a href="#">Tabla 8. Hiperparámetros de la red neuronal MLP</a>                      | 8  |
| <a href="#">Tabla 9. Métricas de la red neuronal MLP</a>                             | 8  |
| <a href="#">Tabla 10. Comparación cuantitativa de los modelos</a>                    | 9  |
| <a href="#">Tabla 11. Comparación cualitativa de los modelos</a>                     | 10 |
| <a href="#">Tabla 12. Correspondencia entre el notebook y el informe</a>             | 11 |
| <a href="#">Tabla 13. Estructura de carpetas relevantes del repositorio</a>          | 11 |
| <a href="#">Tabla 14. Archivos de resultados complementarios</a>                     | 13 |
| <a href="#">Tabla 15. Verificación de alineación con la rúbrica</a>                  | 14 |

## II. Introducción y contextualización

La Fase 2 continúa el proyecto desarrollado por el Grupo 7 con el dataset Iris. Mientras la fase anterior delimitó el problema, describió los datos y estableció la base reproducible, esta etapa formula un subproblema de regresión supervisada: predecir una medida morfológica continua y comparar tres familias de modelos con distinto grado de flexibilidad.

El caso utiliza mediciones de sépalos y pétalos de 150 flores de tres especies. La situación analítica consiste en estimar el ancho del pétalo a partir de su largo. Esta relación permite implementar una regresión lineal simple y, simultáneamente, contrastar si un árbol de decisión o una red neuronal mejoran la predicción al capturar patrones no lineales (Fisher, 1936; Ruete, 2026a).

**Tabla 1**  
*Síntesis del problema analítico*

| Elemento        | Aplicación al caso                                                                    |
|-----------------|---------------------------------------------------------------------------------------|
| Problema        | Estimación de una variable morfológica continua.                                      |
| Dataset         | Iris, 150 observaciones y tres especies.                                              |
| Objetivo        | Ancho del pétalo (cm).                                                                |
| Predictor común | Largo del pétalo (cm).                                                                |
| Decisión        | Seleccionar el modelo con menor error y mayor $R^2$ , considerando interpretabilidad. |

*Nota.* Elaboración propia a partir del planteamiento analítico de la Formativa 2.

## III. Descripción del conjunto de datos y preprocesamiento

Iris contiene cuatro medidas continuas en centímetros y una etiqueta de especie. Para esta fase, la especie se conserva con fines descriptivos y para asegurar representación equilibrada en la partición, pero no participa como variable predictora. El uso de una sola entrada es deliberado: cumple la regresión lineal simple y entrega igualdad de información a los tres modelos.

**Tabla 2***Variables del conjunto de datos y función analítica*

| Variable        | Rol en Fase 2   | Descripción                                               |
|-----------------|-----------------|-----------------------------------------------------------|
| largo_sepalo_cm | Descriptiva     | Largo del sépalo en centímetros.                          |
| ancho_sepalo_cm | Descriptiva     | Ancho del sépalo en centímetros.                          |
| largo_petal_cm  | Predictora      | Única entrada compartida por los modelos.                 |
| ancho_petal_cm  | Objetivo        | Variable continua que se desea estimar.                   |
| especie         | Estratificación | Setosa, versicolor o virginica; no se usa como predictor. |

*Nota.* Elaboración propia a partir del conjunto de datos Iris.

### 3.1 Calidad y tratamiento de datos

- Dimensión validada: 150 filas y seis columnas después de añadir el nombre de especie.
- Valores faltantes: cero; no corresponde imputar ni eliminar registros.
- Dominio: todas las medidas morfológicas son positivas.
- Duplicidad: se conserva una combinación repetida porque no existe identificador individual y puede representar flores distintas con iguales mediciones.

### 3.2 Selección, partición y prevención de fuga

La muestra se dividió en 120 observaciones de entrenamiento (80%) y 30 de prueba (20%), con `random_state=42`. La estratificación por especie dejó diez observaciones de cada especie en prueba. Los índices de entrenamiento y prueba son disjuntos. El escalamiento se ajustó solo con entrenamiento dentro del pipeline de la MLP, evitando que la información de prueba influya en la transformación.

**Tabla 3***Distribución de las observaciones en entrenamiento y prueba*

| Conjunto      | Filas | Porcentaje | Distribución por especie                 |
|---------------|-------|------------|------------------------------------------|
| Entrenamiento | 120   | 80%        | 40 setosa · 40 versicolor · 40 virginica |
| Prueba        | 30    | 20%        | 10 setosa · 10 versicolor · 10 virginica |


*Nota.* Elaboración propia a partir de la partición estratificada con `random_state = 42`.

## IV. Análisis exploratorio inicial

La correlación de Pearson entre largo y ancho del pétalo es alta y positiva. La nube de puntos muestra una estructura creciente y grupos asociados con la especie. Este patrón justifica una línea base lineal, pero también permite evaluar modelos con mayor flexibilidad local.

**Figura 1**

*Relación entre largo y ancho del pétalo, diferenciada por especie*



*Nota.* Elaboración propia a partir del notebook F2\_Regresion.ipynb y del conjunto de datos Iris.

La visualización no se utiliza para incorporar la especie como predictor. Su finalidad es contextualizar la heterogeneidad de la relación. La comparación conserva el mismo predictor para todos los modelos y evita atribuir a un algoritmo una ventaja producida por información adicional.

## V. Modelo de regresión lineal simple

La regresión lineal ordinaria estima una relación global del tipo  $\hat{y} = \beta_0 + \beta_1 x$ , minimizando la suma de residuos cuadrados. Scikit-learn implementa este estimador mediante `LinearRegression` (scikit-learn Developers, 2026a).

**Tabla 4**

*Configuración de la regresión lineal simple*

| Elemento     | Configuración                                                |
|--------------|--------------------------------------------------------------|
| Predictor    | <code>largo_petal_cm</code>                                  |
| Objetivo     | <code>ancho_petal_cm</code>                                  |
| Intercepto   | -0,361761                                                    |
| Coefficiente | 0,415587 cm por cada cm adicional de largo                   |
| Ecuación     | $\hat{y} = -0,3618 + 0,4156 \times \text{largo\_petalo\_cm}$ |

*Nota.* Elaboración propia a partir del ajuste de `LinearRegression` en `F2_Regresion.ipynb`.

El coeficiente positivo indica que, en promedio, un centímetro adicional de largo se asocia con aproximadamente 0,416 cm adicionales de ancho. El modelo es transparente y constituye una referencia interpretable. Su limitación consiste en imponer una pendiente única sobre todo el rango de valores.

**Tabla 5**

*Métricas de la regresión lineal simple*

| MSE      | RMSE        | R <sup>2</sup> |
|----------|-------------|----------------|
| 0,045843 | 0,214109 cm | 0,920658       |

*Nota.* Métricas calculadas sobre las 30 observaciones del conjunto de prueba.

## VI. Árbol de decisión para regresión

El árbol divide recursivamente el espacio del predictor y asigna a cada hoja una predicción constante. El criterio `squared_error` selecciona divisiones que reducen el error cuadrático. La profundidad y el tamaño mínimo de hoja controlan la complejidad y el riesgo de sobreajuste (Ruete, 2026b; scikit-learn Developers, 2026b).

**Tabla 6**

*Hiperparámetros del árbol de decisión*


| Hiperparámetro         | Valor                      | Justificación                     |
|------------------------|----------------------------|-----------------------------------|
| <code>criterion</code> | <code>squared_error</code> | Coherente con la función de error |

| Hiperparámetro    | Valor | Justificación                                         |
|-------------------|-------|-------------------------------------------------------|
|                   |       | evaluada.                                             |
| max_depth         | 3     | Prepoda para evitar reglas excesivamente específicas. |
| min_samples_split | 2     | Mínimo estándar para considerar una división.         |
| min_samples_leaf  | 4     | Evita hojas sostenidas por observaciones aisladas.    |
| random_state      | 42    | Garantiza reproducibilidad.                           |

*Nota.* Elaboración propia a partir de la configuración de DecisionTreeRegressor.

**Figura 2**

*Estructura del árbol de decisión entrenado*



*Nota.* Elaboración propia a partir del notebook F2\_Regresion.ipynb.

**Tabla 7**

*Métricas del árbol de decisión*

| MSE      | RMSE        | R <sup>2</sup> |
|----------|-------------|----------------|
| 0,045315 | 0,212874 cm | 0,921571       |

*Nota.* Métricas calculadas sobre las 30 observaciones del conjunto de prueba.

El árbol mejora levemente la línea base. Su comportamiento escalonado captura cambios locales, aunque la diferencia de error es pequeña. La estructura de tres niveles conserva interpretabilidad y evita memorizar observaciones individuales.

## VII. Red neuronal MLP para regresión

La MLP aproxima funciones no lineales mediante capas conectadas, activaciones y optimización de pesos. Para regresión, la salida es continua y la pérdida cuadrática orienta el entrenamiento (Ruede, 2026c; scikit-learn Developers, 2026c).

**Tabla 8**

*Hiperparámetros de la red neuronal MLP*

| Hiperparámetro     | Valor          | Interpretación                                       |
|--------------------|----------------|------------------------------------------------------|
| hidden_layer_sizes | (16, 8)        | Dos capas ocultas acotadas para una muestra pequeña. |
| activation         | relu           | Introduce no linealidad en capas ocultas.            |
| solver             | lbfgs          | Adecuado para conjuntos pequeños.                    |
| alpha              | 0,001          | Regularización L2 sobre los pesos.                   |
| max_iter           | 5.000          | Límite amplio para convergencia.                     |
| random_state       | 42             | Reproducibilidad.                                    |
| escalamiento       | StandardScaler | Ajustado solo con entrenamiento dentro del pipeline. |

*Nota.* Elaboración propia a partir del pipeline StandardScaler–MLPRegressor.

**Tabla 9**

*Métricas de la red neuronal MLP*

| MSE      | RMSE        | R <sup>2</sup> |
|----------|-------------|----------------|
| 0,037897 | 0,194672 cm | 0,934410       |

*Nota.* Métricas calculadas sobre las 30 observaciones del conjunto de prueba.

La MLP presenta el menor error de prueba y el mayor R<sup>2</sup>. La mejora frente a los otros modelos es real en esta partición, pero moderada. Su principal costo es la menor interpretabilidad; por ello, no corresponde concluir que sea universalmente superior a partir de un dataset pequeño.

## VIII. Evaluación de modelos de regresión

La evaluación se realizó exclusivamente en las 30 observaciones de prueba. El MSE penaliza errores grandes; el RMSE expresa el error típico en centímetros; y R<sup>2</sup> resume la



proporción de variabilidad explicada respecto de una predicción basada en la media.  $R^2$  no prueba causalidad.

**Tabla 10**


*Comparación cuantitativa de los modelos*

| Modelo                  | MSE ↓    | RMSE ↓      | $R^2$ ↑  |
|-------------------------|----------|-------------|----------|
| Red neuronal MLP        | 0,037897 | 0,194672 cm | 0,934410 |
| Árbol de decisión       | 0,045315 | 0,212874 cm | 0,921571 |
| Regresión lineal simple | 0,045843 | 0,214109 cm | 0,920658 |

*Nota.* Elaboración propia a partir de `metricas_modelos.csv`. Las flechas indican la dirección deseable de cada métrica.

**Figura 3**

*Comparación de MSE, RMSE y  $R^2$  en el conjunto de prueba*




*Nota.* Elaboración propia a partir del notebook `F2_Regresion.ipynb`.

## IX. Comparación de modelos

**Figura 4**

*Curvas de predicción y valores reales del conjunto de prueba*



*Nota.* Elaboración propia a partir del notebook F2\_Regresion.ipynb.

**Tabla 11**

*Comparación cualitativa de los modelos*

| Modelo | Fortaleza                                      | Limitación                                       | Decisión                           |
|--------|------------------------------------------------|--------------------------------------------------|------------------------------------|
| Lineal | Máxima interpretabilidad y ecuación explícita. | No captura cambios locales.                      | Mantener como línea base.          |
| Árbol  | Reglas y umbrales comprensibles.               | Predicción escalonada y sensibilidad profunda.   | Usar como contraste interpretable. |
| MLP    | Menor RMSE y mayor $R^2$ .                     | Menor transparencia y necesidad de escalamiento. | Seleccionar preliminarmente.       |

*Nota.* Elaboración propia a partir de los resultados de prueba y de la interpretación de cada modelo.

### 9.1 Elección analítica fundamentada

La red neuronal MLP se selecciona como mejor modelo de esta fase porque obtiene simultáneamente el menor MSE y RMSE y el mayor  $R^2$ . Su RMSE de 0,1947 cm es aproximadamente 9% menor que el de la regresión lineal. No obstante, la cercanía entre

resultados y el tamaño de prueba aconsejan mantener los tres modelos y validar estabilidad mediante validación cruzada en la siguiente fase.

## X. Notebook F2\_Regresion.ipynb y documentación del proceso

El notebook contiene 36 celdas, incluidas 15 de código ejecutadas sin errores. Integra carga, validaciones, análisis exploratorio, partición, entrenamiento, métricas, figuras, exportación de resultados y comprobaciones automáticas. La correspondencia con el informe se resume a continuación.

**Tabla 12**

*Correspondencia entre el notebook y el informe*

| Etapas del notebook | Evidencia                                | Sección del informe |
|---------------------|------------------------------------------|---------------------|
| Carga y calidad     | 150 filas; cero nulos; dominio positivo. | III                 |
| EDA                 | Resumen por especie y Figura 1.          | IV                  |
| Partición           | 120/30; semilla 42; estratificación.     | III                 |
| Modelo lineal       | Ecuación, predicciones y métricas.       | V                   |
| Árbol               | Hiperparámetros, estructura y métricas.  | VI                  |
| MLP                 | Pipeline, arquitectura y métricas.       | VII                 |
| Comparación         | CSV, Figuras 3–4 y selección.            | VIII–IX             |
| Validación integral | Assertions y cierre sin errores.         | X–XI                |

*Nota.* Elaboración propia a partir de la trazabilidad entre el notebook validado y el informe.

### 10.1 Estructura del repositorio

El repositorio organiza la entrega pública mediante carpetas que permiten al docente localizar los datos, el notebook ejecutable, el informe, las figuras, los resultados y los archivos finales. La estructura descrita a continuación se limita a los componentes académicos relevantes para la revisión y excluye materiales administrativos internos.

**Repositorio del Grupo 7:** [Abrir la carpeta Formativa 2 en GitHub](#)

**Tabla 13**

*Estructura de carpetas relevantes del repositorio*

| Ruta          | Contenido académico relevante                      |
|---------------|----------------------------------------------------|
| 02_Datos/     | Dataset Iris utilizado por el análisis.            |
| 03_Notebooks/ | Notebook F2_Regresion.ipynb validado y ejecutable. |
| 04_Informe/   | Informe final en PDF para revisión académica.      |
| 05_Figuras/   | Cuatro figuras PNG generadas por el notebook.      |

| Ruta           | Contenido académico relevante                                     |
|----------------|-------------------------------------------------------------------|
| 06_Resultados/ | Métricas, predicciones y tablas CSV exportadas.                   |
| 09_Entrega/    | Notebook validado e informe PDF que constituyen la entrega final. |

*Nota.* Elaboración propia. La ruta raíz corresponde a Machine Learning 1/Formativa 2.

## XI. Conclusiones

La Formativa 2 mantuvo el dataset Iris de la Sumativa 1 y transformó el proyecto en un problema de regresión continua. La selección de ancho del pétalo como objetivo y largo del pétalo como predictor permitió comparar los tres algoritmos con la misma información y conservar el carácter de regresión lineal simple solicitado.

Los tres modelos alcanzaron  $R^2$  superior a 0,92 en prueba. La regresión lineal ofreció una relación explícita e interpretable; el árbol mejoró marginalmente mediante segmentaciones locales; y la MLP obtuvo el mejor desempeño, con  $MSE=0,037897$ ,  $RMSE=0,194672$  cm y  $R^2=0,934410$ . Por tanto, la MLP se propone como alternativa preliminar de mayor precisión.

La diferencia entre modelos no debe sobredimensionarse. Iris posee solo 150 observaciones y el conjunto de prueba contiene 30. La continuidad del proyecto debe incorporar validación cruzada, análisis de residuos y evaluación de estabilidad. Random Forest y SVR pueden considerarse posteriormente como extensiones, pero no se incorporan ahora porque la actividad exige tres modelos específicos.

Desde la toma de decisiones, el resultado demuestra que una mayor flexibilidad puede reducir el error sin invalidar el valor de modelos simples. La elección dependerá del equilibrio entre precisión, transparencia y capacidad de generalización.

## XII. Uso de fuentes, citación y referencias

- Fisher, R. A. (1936). The use of multiple measurements in taxonomic problems. *Annals of Eugenics*, 7(2), 179–188.  
<https://doi.org/10.1111/j.1469-1809.1936.tb02137.x>
- Ruete, D. (2026a). Regresión lineal simple, polinomial y multivariable [Apunte de clase]. Universidad Andrés Bello.

Ruete, D. (2026b). Regresión con árboles de decisión [Apunte de clase]. Universidad Andrés Bello.

Ruete, D. (2026c). Regresión con redes neuronales artificiales [Apunte de clase]. Universidad Andrés Bello.

Scikit-learn Developers. (2026a). LinearRegression.

[https://scikit-learn.org/stable/modules/generated/sklearn.linear\\_model.LinearRegression.html](https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LinearRegression.html)

Scikit-learn Developers. (2026b). DecisionTreeRegressor.

<https://scikit-learn.org/stable/modules/generated/sklearn.tree.DecisionTreeRegressor.html>

Scikit-learn Developers. (2026c). MLPRegressor.

[https://scikit-learn.org/stable/modules/generated/sklearn.neural\\_network.MLPRegressor.html](https://scikit-learn.org/stable/modules/generated/sklearn.neural_network.MLPRegressor.html)

Scikit-learn Developers. (2026d). Metrics and scoring: Quantifying the quality of predictions.

[https://scikit-learn.org/stable/modules/model\\_evaluation.html](https://scikit-learn.org/stable/modules/model_evaluation.html)

### XIII. Anexos

#### Anexo A. Resultados complementarios exportados

**Tabla 14**

*Archivos de resultados complementarios*

| Archivo                     | Contenido                                                |
|-----------------------------|----------------------------------------------------------|
| metricas_modelos.csv        | MSE, RMSE y $R^2$ de los tres modelos.                   |
| predicciones_prueba.csv     | Valores reales y predicciones para las 30 observaciones. |
| resumen_por_especie.csv     | Estadísticos descriptivos por especie.                   |
| comparacion_cualitativa.csv | Ventajas y limitaciones de los modelos.                  |

*Nota.* Elaboración propia a partir de los archivos generados automáticamente por el notebook.

#### Anexo B. Lista de verificación de la rúbrica

**Tabla 15**

*Verificación de alineación con la rúbrica*

| Criterio        | Evidencia                                          | Estado |
|-----------------|----------------------------------------------------|--------|
| C1 Introducción | Contexto, situación, objetivo y variable continua. | Cumple |
| C2 Datos        | Objetivo, predictor, nulos, selección y partición. | Cumple |
| C3 Lineal       | Ecuación, ejecución, métricas e interpretación.    | Cumple |
| C4 Árbol        | Hiperparámetros, figura, métricas y análisis.      | Cumple |
| C5 MLP          | Arquitectura, pipeline, métricas y análisis.       | Cumple |
| C6 Evaluación   | MSE, RMSE y $R^2$ tabulados.                       | Cumple |
| C7 Comparación  | Mejor modelo, ventajas, límites y decisión.        | Cumple |

| Criterio     | Evidencia                               | Estado |
|--------------|-----------------------------------------|--------|
| C8 Notebook  | 36 celdas; 15 de código; cero errores.  | Cumple |
| Conclusiones | Síntesis, decisión y continuidad.       | Cumple |
| C9–C13       | Plantilla, redacción, fuentes y anexos. | Cumple |

*Nota.* Elaboración propia a partir de la revisión de alineación entre la rúbrica, el notebook y el informe.

La verificación final confirma que el notebook, las cuatro figuras, los resultados y el informe se encuentran organizados en el repositorio del Grupo 7.