

MCDI504

MACHINE LEARNING I

AVANCE DEL PROYECTO — FASE 3:

DESARROLLO DEL PROYECTO

Nombre integrantes:

- Alana Bermúdez
- Gonzalo Mansilla
- Eduardo Villalón

Curso: MCDI504 - Machine Learning I

Docente: David Ruete Zúñiga

Grupo: 7

Fecha: 23 de agosto de 2026

ÍNDICE

I. Portada e índice.....	1
II. Descripción del conjunto de datos y preparación para clasificación.....	3
III. Análisis exploratorio inicial del conjunto de datos.....	4
IV. Notebook F3_Clasificacion.ipynb.....	5
V. Modelo KNN.....	6
VI. Modelo de árboles de decisión.....	7
VII. Modelo SVM.....	8
VIII. Modelo Naïve Bayes.....	9
IX. Evaluación preliminar de modelos de clasificación.....	10
X. Conclusiones.....	11
XI. Uso de fuentes, citación y referencias.....	12
XII. Anexos.....	13

II. Descripción del conjunto de datos y preparación para clasificación

El proyecto utiliza el conjunto de datos Iris, formado por 150 flores pertenecientes a tres especies. El problema analítico consiste en clasificar cada observación como Setosa, Versicolor o Virginica a partir de cuatro medidas morfológicas. Esta formulación corresponde a clasificación supervisada multiclase, porque el modelo aprende desde ejemplos cuya especie es conocida (Fisher, 1936; Universidad Andrés Bello, 2026a).

Tabla 1

Ficha técnica del problema de clasificación

Elemento	Definición aplicada
Dataset	Iris: 150 observaciones y 3 especies balanceadas
Variable objetivo	especie_codigo: 0 = Setosa, 1 = Versicolor, 2 = Virginica
Variables predictoras	Largo y ancho del sépalo; largo y ancho del pétalo (cm)
Entrenamiento/prueba	80/20 estratificado: 120 registros para entrenar y 30 para evaluar
Semilla	42, utilizada para reproducir la partición y los modelos aleatorios
Propósito	Predecir la especie con métricas y condiciones comparables entre modelos

2.1 Preparación analítica

- Se verificaron dimensiones, tipos de datos, rangos, valores faltantes y combinaciones repetidas antes de modelar.
- No se eliminaron registros ni se imputaron valores porque el conjunto no presenta datos faltantes.
- La combinación morfológica repetida se conservó: sin identificador individual no existe evidencia suficiente para afirmar que sea un duplicado inválido.
- La especie textual se mantuvo para interpretación; especie_codigo se utilizó como objetivo numérico.
- La partición se realizó con estratificación, de modo que entrenamiento y prueba conservaran la proporción de las tres clases.
- El escalamiento se ajustó únicamente con entrenamiento en KNN y SVM, evitando fuga de información hacia la prueba.

Decisión metodológica: los cuatro clasificadores se evaluaron sobre las mismas 30 observaciones de prueba. De esta forma, las diferencias no se explican por particiones distintas.

III. Análisis exploratorio inicial del conjunto de datos

La distribución de clases es exactamente balanceada: existen 50 flores Setosa, 50 Versicolor y 50 Virginica. Por ello no se requieren técnicas de rebalanceo. La exploración muestra que las dimensiones del pétalo aportan una separación visual especialmente clara para Setosa, mientras que Versicolor y Virginica presentan cierto solapamiento. Este hallazgo anticipa que los errores se concentrarán principalmente entre estas dos últimas especies.

Tabla 2


Resumen del pétalo por especie

Especie	n	Largo medio	Rango largo	Ancho medio	Rango ancho
Setosa	50	1,462	1,0-1,9	0,246	0,1-0,6
Versicolor	50	4,260	3,0-5,1	1,326	1,0-1,8
Virginica	50	5,552	4,5-6,9	2,026	1,4-2,5

Figura 1

Relación entre largo y ancho del pétalo por especie.

Nota. Elaboración propia a partir de la ejecución reproducible del notebook.



La figura confirma un patrón compatible con el objetivo de clasificación: Setosa forma un grupo claramente separado; Versicolor y Virginica son distinguibles en gran parte del espacio, pero poseen una zona de transición. Esta evidencia justifica comparar métodos basados en distancia, reglas, márgenes y probabilidades.

IV. Notebook F3_Clasificacion.ipynb y documentación del proceso

El notebook organiza el flujo en configuración reproducible, carga y validación, análisis exploratorio, preparación, entrenamiento, evaluación, comparación y cierre. Las celdas narrativas explican qué se hace, por qué se realiza y cómo interpretar los resultados. El archivo oficial se denomina F3_Clasificacion.ipynb y debe coincidir con la versión registrada en el repositorio del equipo.

Tabla 3

Evidencia de reproducibilidad y trazabilidad

Control	Resultado verificado
Ejecución	13 de 13 celdas de código ejecutadas, sin errores
Resultados visibles	Métricas, matrices de confusión, árbol y comparación conservados en el notebook
Artefactos	7 figuras PNG y 6 archivos CSV generados automáticamente
Validaciones	Comprobaciones de modelos, métricas, predicciones y existencia de archivos
Versiones y semilla	Versiones impresas al inicio y semilla 42
Repositorio	Repositorio grupal MCDI500_S1_Grupo7; la copia publicada debe ser idéntica al notebook de entrega

Repositorio de la Formativa 3: [Machine Learning 1 / Formativa 3 — Grupo 7](#)

Comprobación: la última celda detiene la ejecución si falta un modelo, si una métrica sale del rango válido o si no se crean los artefactos esperados.

V. Modelo KNN

K-Nearest Neighbors clasifica cada flor mediante el voto de sus vecinos más próximos. Como las distancias cambian cuando las variables tienen escalas distintas, se utilizó StandardScaler ajustado únicamente con los datos de entrenamiento. La configuración fue $n_neighbors = 5$, pesos uniformes y distancia euclidiana (Scikit-learn developers, s. f.-c; Universidad Andrés Bello, 2026a).

Tabla 4


Configuración y desempeño de KNN

Parámetro o métrica	Valor
n_neighbors	5
Escalamiento	StandardScaler
Accuracy entrenamiento	0,9750
Accuracy prueba	0,9333
Precision macro	0,9444
Recall macro	0,9333
F1 macro	0,9327
Brecha train-test	0,0417

Figura 2

Matriz de confusión del modelo KNN.

Nota. Elaboración propia a partir de la ejecución reproducible del notebook.



KNN clasificó correctamente 28 de 30 flores. Setosa y Versicolor no presentaron errores; dos flores Virginica fueron clasificadas como Versicolor. El resultado es competitivo, aunque la mayor brecha entre entrenamiento y prueba del conjunto comparado sugiere revisar k mediante validación cruzada en la fase final.

VI. Modelo de árboles de decisión

El árbol divide el espacio de características mediante reglas sucesivas. Se aplicó criterio Gini, profundidad máxima 3 y semilla 42. Limitar la profundidad conserva interpretabilidad y reduce el riesgo de memorizar particularidades del entrenamiento (Scikit-learn developers, s. f.-a; Universidad Andrés Bello, 2026a).

Tabla 5


Configuración y desempeño del Árbol de Decisión

Parámetro o métrica	Valor
criterion	gini
max_depth	3
random_state	42
Accuracy entrenamiento	0,9833
Accuracy prueba	0,9667
Precision macro	0,9697
Recall macro	0,9667
F1 macro	0,9666
Brecha train-test	0,0167

Figura 3

Matriz de confusión del Árbol de Decisión.

Nota. Elaboración propia a partir de la ejecución reproducible del notebook.



El árbol obtuvo 29 aciertos de 30. El único error ocurrió entre Versicolor y Virginica, coherente con el solapamiento observado. Su desempeño y la posibilidad de visualizar reglas y umbrales lo convierten en una alternativa útil cuando se necesita explicar la decisión del modelo.

VII. Modelo SVM

SVM busca una frontera que maximice el margen entre clases. Se utilizó kernel radial RBF, $C = 1,0$ y $\gamma = 'scale'$, acompañado de estandarización. Esta configuración permite fronteras no lineales y evita que una variable domine el cálculo por su escala (Scikit-learn developers, s. f.-d; Universidad Andrés Bello, 2026a).

Tabla 6


Configuración y desempeño de SVM

Parámetro o métrica	Valor
kernel	rbf
C	1,0
gamma	scale
Escalamiento	StandardScaler
Accuracy entrenamiento	0,9750
Accuracy prueba	0,9667
Precision macro	0,9697
Recall macro	0,9667
F1 macro	0,9666
Brecha train-test	0,0083

Figura 4

Matriz de confusión del modelo SVM.

Nota. Elaboración propia a partir de la ejecución reproducible del notebook.



SVM obtuvo 29 aciertos y la menor brecha train-test del grupo, empatada con Naïve Bayes. El resultado indica buena generalización en esta partición; su principal limitación práctica es que la frontera RBF resulta menos interpretable que las reglas de un árbol.

VIII. Modelo Naïve Bayes

Se utilizó GaussianNB porque las cuatro variables predictoras son continuas. El modelo estima distribuciones gaussianas por clase y aplica el teorema de Bayes bajo un supuesto simplificador de independencia condicional entre predictores (Scikit-learn developers, s. f.-b; Universidad Andrés Bello, 2026a).

Tabla 7


Configuración y desempeño de Naïve Bayes

Parámetro o métrica	Valor
Variante	GaussianNB
var_smoothing	1e-09
Escalamiento	No requerido
Accuracy entrenamiento	0,9583
Accuracy prueba	0,9667
Precision macro	0,9697
Recall macro	0,9667
F1 macro	0,9666
Brecha train-test	0,0083

Figura 5

Matriz de confusión de Naïve Bayes.

Nota. Elaboración propia a partir de la ejecución reproducible del notebook.



Naïve Bayes obtuvo 29 aciertos de 30. Su fortaleza es la simplicidad y el bajo costo computacional. La principal limitación es que las medidas de sépalo y pétalo presentan correlaciones, por lo que el supuesto de independencia no se cumple estrictamente.

IX. Evaluación preliminar de modelos de clasificación

La evaluación usa accuracy, precision macro, recall macro, F1 macro y la brecha absoluta entre accuracy de entrenamiento y prueba. Las métricas macro entregan el mismo peso a las tres especies, lo que facilita una comparación equilibrada. La matriz de confusión complementa los promedios al mostrar la clase específica de cada error.

Tabla 8


Comparación de los cuatro clasificadores

Modelo	Acc. train	Acc. test	Prec. macro	Recall macro	F1 macro	Brecha
KNN	0,9750	0,9333	0,9444	0,9333	0,9327	0,0417
Árbol de Decisión	0,9833	0,9667	0,9697	0,9667	0,9666	0,0167
SVM RBF	0,9750	0,9667	0,9697	0,9667	0,9666	0,0083
Naïve Bayes	0,9583	0,9667	0,9697	0,9667	0,9666	0,0083

Figura 6

Comparación de métricas en el conjunto de prueba.

Nota. Elaboración propia a partir de la ejecución reproducible del notebook.



Árbol de Decisión, SVM y Naïve Bayes empataron con accuracy de 0,9667 y F1 macro de 0,9666. KNN alcanzó accuracy de 0,9333 y F1 macro de 0,9327. La diferencia corresponde a un error adicional de KNN dentro de un conjunto de prueba pequeño.

Selección preliminar: se propone continuar con el Árbol de Decisión, porque conserva el mejor desempeño observado y permite explicar reglas y umbrales. El empate impide declarar superioridad estadística; la decisión debe confirmarse en el informe final mediante validación cruzada y ajuste de hiperparámetros.

9.1 Fortalezas y limitaciones

Tabla 9

Fortalezas y limitaciones de los modelos

Modelo	Fortaleza principal	Limitación principal
KNN	Intuitivo y flexible localmente	Sensible a escala y elección de k
Árbol	Reglas visibles e interpretables	Puede ser inestable y sobreajustar
SVM	Frontera robusta y no lineal	Menor interpretabilidad y requiere escalado
Naïve Bayes	Rápido y simple	Supuesto de independencia restrictivo

X. Conclusiones

1. El dataset Iris permite formular un problema de clasificación multiclase coherente: la especie es la variable objetivo y las cuatro medidas morfológicas constituyen predictores pertinentes.
2. La revisión de calidad confirmó 150 observaciones, ausencia de valores faltantes y clases balanceadas. La partición estratificada 80/20 mantuvo diez observaciones de cada especie en prueba.
3. Las dimensiones del pétalo separan claramente a Setosa; el solapamiento entre Versicolor y Virginica explica la ubicación de los errores observados.
4. Árbol de Decisión, SVM y Naïve Bayes obtuvieron 29 aciertos de 30, mientras KNN obtuvo 28. Debido al tamaño del conjunto de prueba, el resultado debe interpretarse como evidencia preliminar y no como superioridad definitiva.
5. El Árbol de Decisión se selecciona preliminarmente por combinar desempeño e interpretabilidad. La fase final deberá comprobar estabilidad con validación cruzada y ajuste de hiperparámetros antes de establecer una decisión definitiva.
6. La ejecución reproducible, las validaciones automáticas y la exportación de figuras y tablas aseguran trazabilidad entre notebook, informe y repositorio.

Como implicancia para la toma de decisiones, el análisis muestra que una métrica global no basta: también debe revisarse qué clases se confunden, la brecha entre entrenamiento y prueba, los supuestos del algoritmo y la facilidad para explicar el resultado.

XI. Uso de fuentes, citación y referencias

Fisher, R. A. (1936). The use of multiple measurements in taxonomic problems. *Annals of Eugenics*, 7(2), 179–188. <https://doi.org/10.1111/j.1469-1809.1936.tb02137.x>

Scikit-learn developers. (s. f.-a). DecisionTreeClassifier. Scikit-learn documentation. Recuperado el 20 de agosto de 2026, de <https://scikit-learn.org/stable/modules/generated/sklearn.tree.DecisionTreeClassifier.html>

Scikit-learn developers. (s. f.-b). GaussianNB. Scikit-learn documentation. Recuperado el 20 de agosto de 2026, de https://scikit-learn.org/stable/modules/generated/sklearn.naive_bayes.GaussianNB.html

Scikit-learn developers. (s. f.-c). KNeighborsClassifier. Scikit-learn documentation. Recuperado el 20 de agosto de 2026, de <https://scikit-learn.org/stable/modules/generated/sklearn.neighbors.KNeighborsClassifier.html>

Scikit-learn developers. (s. f.-d). SVC. Scikit-learn documentation. Recuperado el 20 de agosto de 2026, de <https://scikit-learn.org/stable/modules/generated/sklearn.svm.SVC.html>

Universidad Andrés Bello. (2026a). Presentación Fase 3: clasificación supervisada [Presentación de clase]. Curso MCDI504 Machine Learning I.

Universidad Andrés Bello. (2026b). Fase 3, avance semana 3 formativa [Notebook docente]. Curso MCDI504 Machine Learning I.

Scikit-learn developers. (2026d). GaussianNB. Scikit-learn documentation.


https://scikit-learn.org/stable/modules/generated/sklearn.naive_bayes.GaussianNB.html

XII. Anexos

Anexo A. Visualización del Árbol de Decisión

Figura A1

Estructura del Árbol de Decisión con profundidad máxima 3.
 Nota. Elaboración propia a partir de la ejecución reproducible del notebook.



Anexo B. Inventario de artefactos reproducibles

Tabla A1

Archivos generados por el notebook

Carpeta	Archivos	Uso en el informe
05_Figuras	figura_1 a figura_7 (.png)	EDA, matrices, árbol y comparación
06_Resultados	resumen_por_especie.csv	Estadística descriptiva por clase
06_Resultados	metricas_knn.csv	Resultados KNN
06_Resultados	metricas_arbol_decision.csv	Resultados Árbol
06_Resultados	metricas_svm.csv	Resultados SVM
06_Resultados	metricas_naive_bayes.csv	Resultados Naïve Bayes
06_Resultados	comparacion_modelos.csv	Tabla comparativa común

Anexo C. Matriz de trazabilidad con la rúbrica de Canvas

Tabla A2

Evidencia asociada a los 13 criterios efectivos

Criterio	Evidencia principal
C1 Dataset y preparación	Sección II, tabla 1 y notebook secciones 2 y 4
C2 Análisis exploratorio	Sección III, tabla 2 y figura 1
C3 Notebook	Sección IV, tabla 3 y F3_Clasificacion.ipynb
C4 KNN	Sección V, tabla 4 y figura 2
C5 Árbol de decisión	Sección VI, tabla 5, figura 3 y anexo A
C6 SVM	Sección VII, tabla 6 y figura 4
C7 Naïve Bayes	Sección VIII, tabla 7 y figura 5
C8 Evaluación preliminar	Sección IX, tabla 8 y figura 6
C9 Portada e índice	Páginas 1 y 2 del entregable institucional
C10 Formato institucional	Documento tamaño carta y PDF con plantilla UNAB
C11 Ortografía y gramática	Revisión integral del informe
C12 Fuentes y referencias	Sección XI: 2 docentes, 4 oficiales y 1 académica
C13 Anexos	Anexos A-C con figuras, archivos y trazabilidad